

מדריך למידת עומק

בעזרת המסמך הזה אפשר לאמן מודלים של למידה עמוקה בצורה יעילה יותר. במסמך הזה מודגש כוונן היפר-פרמטרים, אבל הוא גם עוסק בהיבטים אחרים של אימון למידה עמוקה (Deep Learning) כמו הטמעה של צינור עיבוד אימון ואופטימיזציה.

במסמך הזה ההנחה היא שמשימת למידת המכונה היא בעיה בלמידה בפיקוח או בעיה דומה (למשל, למידה בפיקוח עצמי, (עם זאת, חלק מהעצות במסמך הזה עשויות לחול גם על סוגים אחרים של בעיות בלמידת מכונה.

הערה: המסמך הזה מבוסס על גרסה קודמת, שנשמרת ב-GitHub-השמות והשינויים של המחברים זמינים בגרסת.github

קהל היעד

שיתפנו את המסמך הזה למהנדסים ולחוקרים באמצעות ידע בסיסי לפחות בלמידת מכונה ובלמידה עמוקה (Deep Learning) אם אין לכם את הרקע הזה, כדאי לכם להשתתף בקורס קריסה של למידת מכונה.

למה כתבנו את המסמך הזה?

נכון לעכשיו, יש כמות מדהימה של טרחה וניחושים לצורך יצירת רשתות נוירונים עמוקות, כדי שיפעלו כהלכה. ועוד יותר גרוע, המתכונים שאנשים משתמשים בהם כדי להגיע לתוצאות טובות באמצעות למידה עמוקה מתועדים לעתים רחוקות. דפים מבריקים את התהליך שהוביל לתוצאות הסופיות שלהם, בסדר שבו הם מציגים סיפור נקי יותר. כמו כן, למהנדסי למידת מכונה שעובדים על בעיות מסחריות אין מספיק זמן כדי לקחת צעד לאחור ולכלול את התהליך שלהם. ספרי לימוד נוטים להימנע מהנחיות מעשיות ולתעדף עקרונות בסיסיים, גם אם למחברים שלהם יש את הניסיון הנחוץ בעבודה המוחלת כדי לספק עצות מועילות.

במהלך ההכנה ליצירת המסמך, לא הצלחנו למצוא ניסיון מקיף להסביר איך להשיג תוצאות טובות בעזרת למידה עמוקה. במקום זאת, מצאנו קטעי עצות בפוסטים בבלוגים ובמדיה החברתית, טריקים להצצה מתוך מאמרי מחקר, מקרים לדוגמה על פרויקט או צינור אחד, והרבה בלבול. יש טווח עצום בין התוצאות של מומחי למידה עמוקה, לבין בעלי מקצוע פחות מיומנים שמשתמשים בשיטות דומות מאוד. עם זאת, המומחים מודים בבירור שחלק מהפעולות שלהם לא מוצדקות. ככל שלומדים עמוקים ומשפיעים יותר על העולם, הקהילה זקוקה ליותר משאבים שעוסקים במתכונים שימושיים, כולל כל הפרטים המעשיים שיכולים להיות כל כך קריטיים להשגת תוצאות טובות.

אנחנו צוות של חמישה חוקרים ומהנדסים שעבדו בתחום הלמידה עמוקה בשנים האחרונות, וחלקם כבר משנת 2006. יישמנו למידה עמוקה בכל נושא, מזיהוי דיבור ועד אסטרונמיה. המסמך הזה גדל מניסיון שלנו בהדרכה ברשתות נוירונים, ללימוד מהנדסי למידת מכונה חדשים ולייעוץ לקולגות שלנו לגבי ניסיון בלמידה עמוקה (Deep Learning).

היה סיפוק לראות איך למידה עמוקה נבנתה מגישת למידת מכונה שבוצעה על ידי מספר בדיקות אקדמיות ועד לטכנולוגיה שמופעלת על ידי מיליארדי אנשים. עם זאת, למידה עמוקה נמצאת עדיין בחיתוליה בתחום ההנדסה, ואנחנו מקווים שהמסמך הזה מעודד אחרים לעזור במערכת של פרוטוקולים ניסיוניים של השדה.

מסמך זה נוצר כשניסו לנסח בצורה טובה יותר את הגישה שלנו ללמידה עמוקה. ולכן הוא מייצג את הדעות שלנו נכון לזמן הכתיבה, ולא שום אמת אובייקטיבית. המאבק שלנו עם כוונן פרמטרים היפר-פרמטרים הפך את המיקוד למוקד מסוים, אך הוא גם מכסה בעיות חשובות אחרות שבהן נתקלנו בעבודה שלנו (או שראינו שהן שגויות). הכוונה שלנו היא שהתוכן הזה הוא מסמך חי שמתפתח ומשתנה ככל שהאמונה שלנו משתנה. לדוגמה, לפני פחות משנתיים לא היינו יכולים לכתוב את המאמר על ניפוי באגים וצמצום כשלים בהכשרה, כי הוא מבוסס על תוצאות אחרונות ועל חקירות מתמשכות.

סביר להניח שתצטרכו לעדכן כמה מהעצות שלנו כדי להביא בחשבון תוצאות חדשות ותהליכי עבודה משופרים. אנחנו לא מכירים את התהליכים האופטימליים של למידה עמוקה, אבל עד שהקהילה תתחיל

לכתוב ולדון בהליכים שונים, אנחנו לא מקווים למצוא אותה. לשם כך, אנחנו מעודדים את הקוראים שמצאו בעיות בעצות שלנו להפיק המלצות חלופיות, כמו גם ראיות משכנעות, כדי שנוכל לעדכן את המדריך. נשמח גם לראות מדריכים וספרי הדרכה חלופיים עם המלצות שונות, כדי שנוכל ליישם שיטות מומלצות כקהילה.

מידע על האמוג'י רובוט

האמוג'י רובוט 🤖 מציין איפה אנחנו רוצים לחקור יותר לעומק. רק אחרי שניסיתי לכתוב את המדריך הזה, הבנתי באופן ברור כמה שאלות מעניינות ומוזנחות נמצאו בתהליך העבודה של מי שעוסק בלמידה עמוקה.

מדריך להתחלת פרויקט חדש

בקטע הזה נסביר איך לבחור את האפשרויות הבאות בתחילת בפרויקט למידת מכונה:

- את ארכיטקטורת המודל
- האופטימיזציה
- גודל הקבוצה
- את ההגדרה הראשונית

טיפ: מקבלים החלטות לגבי הכוונן כבר בתחילת של הפרויקט. לאחר מכן, חזרו אליהם ההחלטות מתקבלות רק כשהנסיבות משתנות.

הנחות

העצות בקטע הזה מבוססות על ההנחה הבאה:

- כבר [ניסינו את הבעיה](#), והכינו את נתוני האימון שלכם במידה מסוימת.
 - כבר הגדרתם צינור עיבוד נתונים להדרכה ולבדיקה.
 - כבר בחרתם והטמעתם מדדים שמייצגים כמה שיותר ממה שאתם מתכננים למדוד בסביבה שנפרסה.
- בהנחה שעמדתם בכל הדרישות המוקדמות שמפורטות בהמשך, אתם מוכנים להקדיש זמן לארכיטקטורת המודל ולתצורת האימון.

בחירת הארכיטקטורה של המודל

טיפ: כשיוצרים פרויקט חדש, כדאי להשתמש שוב בארכיטקטורת מודלים כבר עובד. אם אין לכם מודל עבודה, לפחות השתמשו במודל של ארכיטקטורת מקודד-מפענח מסורתית. **טיפ:** כדי להתחיל לעבוד, תיצרו ארכיטקטורת מודלים ותיקה ונפוצה. שלך יכולים לבנות מודל מותאם אישית מאוחר יותר.

נתחיל עם ההגדרות הבאות:

- **ארכיטקטורת מודל** היא מערכת ליצירת חיזויים. ארכיטקטורת מודלים מכילה את ה-framework-להמרת נתוני קלט לחיזויים, אבל לא מכיל [פרמטר](#). לדוגמה, רשת נוירונים עם שלוש שכבות נסתרות של 10 צמתים, 5 צמתים ו-3 צמתים בהתאמה, הוא ארכיטקטורת מודל.
- **מודל** הוא ארכיטקטורת מודל וגם ערכים ספציפיים לכל. לדוגמה, מודל מורכב מרשת הנוירונים שמתוארת. בהגדרה של ארכיטקטורת מודל, בתוספת ערכים ספציפיים המשקולות וההטיה של כל צומת.
- **משפחת מודלים** היא תבנית לבניית ארכיטקטורת מודלים בהינתן קבוצה של [היפר-פרמטרים](#).

בחירה בארכיטקטורת המודל פירושה בחירה של ארכיטקטורת מודלים (אחד לכל הגדרה של ההיפר-פרמטרים במודל).

במידת האפשר, כדאי לנסות למצוא בסיס קוד מתועד שמספק מענה למשהו קרובים ככל האפשר לבעיה הנוכחית. לאחר מכן, משחזרים את המודל בתור בתור נקודת מוצא.

בחירת כלי האופטימיזציה

טיפ: כדאי להתחיל עם הנכסים הכי פופולריים ([אופטימיזציה](#)) לדוגמה Adam, או (AdaGrad לסוג הבעיה שעליה אתם עובדים).

אין כלי אופטימיזציה "הטוב ביותר" בכל הסוגים של בעיות למידת מכונה וארכיטקטורות של מודלים. אפילו רק השוואת הביצועים של האופטימיזציה קשה. 🤖 מומלץ להשתמש בכלי אופטימיזציה פופולריים ומבוססים במיוחד כשיוצרים פרויקט חדש.

מומלץ לבחור את כלי האופטימיזציה הפופולרי ביותר לסוג הבעיה שעליה אתם עובדים. מומלץ להשתמש בכלי האופטימיזציה המוכרים הבאים:

- [SGD עם מומנטום](#). אנחנו ממליצים על הווריאנט של Nesterov.
 - [Adam](#) ו-[NAdam](#) - שהם כלליים יותר מ-SGD - עם מומנטום. שימו לב של Adam יש ארבעה ארגומנטים שניתן לכוון הם יכולים להיות חשובים! ראה [כיצד צריכים להיות ההיפר-פרמטרים של Adam לכוון?](#)
- יש לשים לב לכל הארגומנטים של כלי האופטימיזציה שנבחר. כדי לשפר את האופטימיזציה עם יותר היפר-פרמטרים, בדרך כלל נדרש מאמץ כוונן גדול יותר. זה מכאיב במיוחד בשלבים הראשונים של פרויקט, ניסית למצוא את הערכים הכי טובים של היפר-פרמטרים שונים (לדוגמה, שיעור למידה) בזמן התייחסות לארגומנטים של אופטימיזציה מטרדים. לכן מומלץ לפעול לפי הגישה הבאה:

1. בתחילת הפרויקט, יש לבחור מומחה אופטימיזציה שאין בו הרבה תרגומים היפר-פרמטרים. הנה שתי דוגמאות:

- SGD עם תנע קבוע.
 - Adam עם Beta1, Epsilon, Beta2 - קבועים.
2. בשלבים מאוחרים יותר של הפרויקט, לעבור לכלי אופטימיזציה כללי יותר מכווננת יותר היפר-פרמטרים במקום לתקן אותם לערכי ברירת המחדל.

בחירת גודל הקבוצה

טיפ: לעיתים קרובות, הגודל האידיאלי של קבוצת הקבצים הוא גודל הקבוצה הגדול ביותר שיש תמיכה בחומרה זמינה.

סיכום: גודל המקבץ קובע את מהירות האימון. לא להשתמש בגודל אצווה כדי לכוון ישירות את הביצועים של קבוצת האימות.

גודל האצווה קובע במידה רבה את זמן האימון ומשאב המחשוב צריכה. הרבה פעמים, הגדלה של כמות הקבצים מקצרת את זמן האימון. אשר:

- מאפשר לכוון היפר-פרמטרים באופן יסודי יותר בתוך זמן קבוע וכך ליצור מודל סופי טוב יותר.
 - מפחית את זמן האחזור של מחזור הפיתוח, ומאפשר לרעיונות חדשים נבדקים בתדירות גבוהה יותר.
- הגדלה של קבוצת הקבצים עלולה להקטין או להגדיל את צריכת המשאבים. או להשאיר את צריכת המשאבים ללא שינוי.
- אין להתייחס לגודל אצווה כאל היפר-פרמטר שניתן לכוון לצורך [אימות הגדרת הביצועים](#). אם כל החישובים האלה שהתנאים הבאים מתקיימים, ביצועי המודל לא יכולים להיות תלויים גודל אצווה:
- כל ההיפר-פרמטרים של כלי האופטימיזציה מכווננים היטב.

- הסדרת נתונים מספיקה ומכווננת היטב.
- מספר שלבי האימון מספיק מספיק.

יש להשיג את אותם הביצועים הסופיים בכל גודל של קבוצה (ראו [Shallue et al. 2018](#) וגם [למה אין לכוון את גודל קבוצת הקבצים כדי לשפר באופן ישיר לביצועים של קבוצת האימון?](#))

מצאו את הגדלים האפשריים של האצווה והערכה של תפוקת האימון.

לדגם מסוים וכלי אופטימיזציה מסוימים, החומרה הזמינה בדרך כלל תומכת טווח של גדלים מרובים. בדרך כלל הגורם המגביל הוא זיכרון מאיץ. לצערי, קשה לחשב את גודל אצווה יתאים לזיכרון ללא הרצה, או לפחות הידור, תוכנית אימון מלאה. הפתרון הקל ביותר הוא בדרך כלל להריץ משימות אימון בגדלים שונים (לדוגמה, הגדלת החזקות של 2) מספר השלבים עד שאחת מהמשימות תחרוג מהזיכרון הזמין. עבור האימון של כל קבוצה, מספיק זמן כדי לקבל הערכה אמינה **תפוקת האימון**:

תפוקת האימון = מספר הדוגמאות שעברו עיבוד בשנייה

או לחלופין, **בכל שלב**:

זמן לכל שלב = גודל הקבוצה / תפוקת אימון

כשהמאצים עדיין לא רוויים, אם גודל ההאצה מוכפל, גם תפוקת האימון צריכה להיות כפולה (או כמעט כפולה). שווה ערך לכך, הזמן לכל שלב צריך להיות קבוע (או לפחות קבוע) ככל שגודל קבוצת הקבצים גדל. אם זה לא המצב, לצינור האימון יש צוואר בקבוק, כמו קלט/פלט (I/O) או סנכרון בין צומתי מחשוב. מומלץ לאבחן ולתקן את צוואר הבקבוק לפני שממשיכים.

אם תפוקת האימון גדלת עד לגודל מקסימלי מסוים של אצווה, מומלץ להביא בחשבון רק גדלים מרובים של קבוצות עד לגודל המקסימלי הזה, גם אם החומרה תומכת בכמות גדולה יותר של קבצים. כל היתרונות של שימוש בכמות גדולה יותר מניחים את תפוקת האימון. אם לא, צריך לתקן את צוואר הבקבוק או להשתמש בכמות קטנה יותר.

צבירה הדרגתית מדמה גודל אצווה גדול יותר מהחומרה ולכן היא לא מספקת יתרונות תפוקה. אתם צריכים בדרך כלל להימנע מהצטברות הדרגתית בעבודה יושמה.

ייתכן שתצטרכו לחזור על השלבים האלה בכל פעם שתשנו את המודל, את האופטימיזציה. לדוגמה, ארכיטקטורת מודלים שונה עשויה לאפשר אצווה גדולה יותר כדי שתתאים לזיכרון.

כדאי לבחור את גודל הקבוצה כדי לקצר את זמן האימון

זאת ההגדרה שלנו **לזמן אימון**:

- $\text{זמן האימון} = (\text{זמן לכל שלב}) \times \text{מספר הצעדים הכולל}$

לרוב אפשר להתייחס לזמן בכל שלב כזמן קבוע יחסית לכל הגדלים האפשריים באצווה. הדבר נכון במקרים הבאים:

- אין תקורה מחישובים מקבילים.
- כל צווארי הבקבוק באימון אובחנו ותוקנו ([בקטע הקודם](#) מוסבר איך מזהים). צווארי בקבוק באימון. בפועל, בדרך כלל יש מהגדלת מספר הקבצים.

ככל שכמות הקבצים גדולה יותר, כך נדרש מספר השלבים הכולל בדרך כלל יעד ביצועים קבוע יורד, בתנאי היפר-פרמטרים רלוונטיים כשמשנים את גודל הקבוצה. (ראו [Shallue et al. 2018](#) לדוגמה, הכפלת גודל האצווה עשויה להקטין בחצי את המספר הכולל של שנדרשים. הקשר הזה נקרא **התאמה מושלמת** והוא צריך להחזיק את כל הגדלים עבור קבוצת הקבצים עד גודל אצווה קריטי.

מעבר לגודל הקריטי של אצווה, הגדלת גודל קבוצת הקבצים יוצרת עם ירידה בהחזרות. כלומר, בסופו של דבר נגדיל את כמות הקבצים לא מפחית את מספר שלבי האימון אבל אף פעם לא מגדיל אותו. לכן, בדרך כלל הגודל של קבוצת הקבצים שמצמצם את זמן האימון הוא קבוצת הקבצים **הגדולה ביותר** שעדיין מפחיתה את מספר שלבי האימון נדרש. גודל אצווה זה תלוי במערך הנתונים, במודל וכלי האופטימיזציה, וזו בעיה פתוחה לגבי האופן שבו מחשבים אותם מלבד למצוא אותו באופן ניסיוני לכל בעיה חדשה 🤖.

כשמשווים בין גודל של כמה מערכי אצווה, חשוב לשים לב להבחנה בין הדברים הבאים:

- **תקציב לדוגמה או תקציב לתקופת זמן של ניסיון** – הפעלת כל הניסויים בזמן תיקון מספר המצגות לדוגמה לאימון.

- הגדרת תקציב שלבים – הפעלת כל הניסויים עם מספר קבוע של שלבי האימון.

השוואת גדלים של קבוצות מרובות עם תקציב של תקופת זמן מסוימת רק עוזרת למצוא את הפתרון המושלם של התאמה לעומס (scaling) גם כאשר אצווה גדולות יותר עדיין עשויות לספק להאיץ משמעותית את מספר שלבי האימון הנדרשים. לעיתים קרובות, גודל הקבצים הגדול ביותר שנתמך על ידי החומרה הזמינה קטן יותר מגודל הקבוצה הקריטית. לכן, כלל טוב היא להשתמש בקבוצה הגדולה ביותר ככל האפשר. אין טעם להשתמש בכמות גדולה יותר אם היא מסתיימת להארכת זמן האימון.

לבחור את גודל האצווה כדי לצמצם את צריכת המשאבים

יש שני סוגים של עלויות משאבים שקשורות להגדלת הנפח באצווה:

- **עלויות מראש**. לדוגמה, רכישת חומרה חדשה או שכתוב לצינור עיבוד נתונים כדי להטמיע אימונים מרובי מעבדי / GPU מולטי TPU.

- **עלויות שימוש**. לדוגמה, חיוב לפי תקציבי המשאבים של הצוות, חיוב מספק שירותי ענן, עלויות חשמל ותחזוקה.

אם יש עלויות משמעותיות מראש להגדלת הכמות של הקבצים באצווה, אולי כדאי יותר לדחות את הגדלת מספר הקבצים עד שהפריקט ותיקח קל יותר להעריך את האיזון בין העלות מבחינת העלות. הטמעת תוכניות הדרכה מקבילות עם מארחים מרובים יכולה להציג **באגים** וגם **בעיות עדינות** לכן כדאי להתחיל בשפה פשוטה יותר צינור עיבוד נתונים בכל מקרה. מצד שני, האצה משמעותית בזמן האימון עשויה להיות שימושית מאוד בשלב מוקדם בתהליך, נדרשים ניסויים.

אנחנו מתייחסים לעלות השימוש הכוללת (שעשויה לכלול כמה סוגים של עלויות שונות) כצריכת המשאבים, שמחושבת באופן הבא:

צריכת משאבים = צריכת משאבים לכל שלב x מספר השלבים הכולל

בדרך כלל, הגדלת הקבוצה מקטינה את מספר השלבים הכולל. העלייה או הירידה בצריכת המשאבים תלויה בגורמים הבאים: האופן שבו הצריכה לכל שלב משתנה, שתלויה בגודל קבוצת הקבצים באופן הבא:

- הגדלת הקובץ באצווה עשויה להקטין את צריכת המשאבים. לדוגמה, אם אפשר להריץ כל שלב בגודל אצווה גדול יותר באותה חומרה כמו הקבוצה הקטנה יותר (עם במשך הזמן בכל שלב), ואז כל עלייה במשאב לצריכה לכל שלב עשויה להיות מושפעת מהירידה במספר השלבים.

- הגדלת הקובץ באצווה עשויה לא לשנות את צריכת המשאבים. לדוגמה, אם הכפלת הגודל של אצווה גורמת לחצוים את מספר השלבים נדרש ומכפיל את מספר יחידות ה-GPU בשימוש, הצריכה הכוללת (במונחים של שעות GPU) לא משתנה.

- הגדלת הקובץ באצווה עשויה להגדיל את צריכת המשאבים. לדוגמה, אם כדי להגדיל את קבוצת הקבצים צריך חומרה משודרגת, ההגדלה בצריכה לכל שלב עשויה לעלות על הירידה את מספר השלבים.

שינוי הגודל של קבוצת הקבצים דורש כוונן מחדש של רוב ההיפר-פרמטרים

הערכים האופטימליים של רוב ההיפר-פרמטרים הם רגישים לגודל הקבוצה. לכן, שינוי גודל הקבוצה בדרך כלל מחייב התחלת כוונן את כל העיבוד שוב. ההיפר-פרמטרים בעלי האינטראקציה החזקה ביותר לכמות גדולה של נתונים, ולכן הכי חשוב לבצע כוונן בנפרד לכל גודל של קבוצת קבצים באופן הבא:

- ההיפר-פרמטרים של כלי האופטימיזציה (לדוגמה, קצב למידה ותנע)
- ההיפר-פרמטרים של הרגולריזציה

חשוב לשים לב לכך כשבוחרים את גודל קבוצת הקבצים בתחילת הפרויקט. אם יהיה צורך לעבור לגודל אחר של אצווה בשלב מאוחר יותר, יכול להיות קשה, גוזל זמן ויקר כדי לבצע כוונן מחדש של ההיפר-פרמטרים האחרים עבור גודל אצווה חדש.

האופן שבו נורמה באצווה מקיימת אינטראקציה עם גודל הקבוצה

נורמה של אצווה היא מורכבת, ובאופן כללי, כדאי להשתמש בקבוצת אצווה שונה מהגודל ההדרגתי בהשוואה לחישוב ההדרגתי לצורך חישוב הנתונים הסטטיסטיים. צפייה [הטמעת נירמול באצווה](#) לדיון מפורט.

בחירת ההגדרה הראשונית

השלב הראשון בכוונן היפר-פרמטרים הוא נקודות התחלה עבור:

- את תצורת המודל (למשל, מספר השכבות)
- ההיפר-פרמטרים של כלי האופטימיזציה (למשל, קצב הלמידה)
- מספר שלבי האימון

כדי לקבוע את ההגדרות האישיות האלה בצורה ידנית, הרצות אימון מוגדרות וניסוי וטעמה.

העיקרון המנחה שלנו הוא:

מציאת דרך פשוטה, מהירה יחסית, עם צריכת משאבים נמוכה יחסית שמשיגת ביצועים סבירים.

איפה:

- פשטות היא הימנעות מתכונות של צינור עיבוד נתונים מיותרות, כמו הגדרות קבועות או טריקים ארכיטקטוניים. לדוגמה, צינור עיבוד נתונים [נטישה רגילה](#) (או אם הרגולריזציה של נטישה מושבתת) הוא פשוט יותר מערך אחד הרגולריזציה של נטישה.

- ביצועים סבירים תלויים בבעיה, אבל לפחות מודל מאומן סביר מבצע ביצועים הרבה יותר טובים ממודל אקראי בקבוצת האימון.

לבחור הגדרה ראשונית מהירה שצורכת מינימלי כוונן של היפר-פרמטרים מתבצע ביעילות רבה יותר. לדוגמה, תוכלו להתחיל עם מודל קטן יותר.

בחירת מספר שלבי האימון כוללת איזון של המתח הבא:

- הדרכה על שלבים נוספים יכולה לשפר את הביצועים ולפשט את ההיפר-פרמטרים של כוונן עדין. (פרטים נוספים זמינים במאמר [Shallue et al. 2018](#)).

- לעומת זאת, אימון למספר קטן יותר של צעדים פירושו שכל הרצת אימון מהיר יותר ומנצל פחות משאבים, וכך משפר את יעילות הכוונן על ידי הפחתת את פרק הזמן בין מחזורים ומאפשרים לכם להריץ יותר ניסויים במקביל. בנוסף, אם בחרת תקציב שלבים גדול שלא לצורך בתחילת ייתכן שיהיה קשה לשנות זאת בשלב מאוחר יותר במהלך הפרויקט. לדוגמה, אחרי שהתאמתם את לוח הזמנים של קצב הלמידה למספר השלבים הזה.

גישה מדעית לשיפור ביצועי המודל

למטרות המסמך הזה:

המטרה הסופית של פיתוח למידת מכונה היא למקסם את התועלת של המודל שנפרס.

בדרך כלל אפשר להשתמש באותם שלבים ועקרונות בסיסיים שמופיעים בקטע הזה לכל בעיה של למידת מכונה.

ההנחות בקטע הזה:

- כבר יש לכם צינור אימון שפועל באופן מלא, וגם הגדרה שמניבה תוצאה סבירה.
- יש לכם מספיק משאבי מחשוב כדי לבצע ניסויים משמעותיים של התאמה וכדי להריץ לפחות כמה משימות אימון במקביל.

אסטרטגיית הכוונן המצטבר

המלצה: כדאי להתחיל עם הגדרה פשוטה. לאחר מכן, מבצעים שיפורים בהדרגה תוך כדי קבלת תובנות לגבי הבעיה. חשוב לוודא שכל שיפור מבוסס על ראיות חזקות.

אנחנו מניחים שהמטרה שלך היא למצוא הגדרה שתמקסם את הביצועים של המודל. לפעמים המטרה היא לשפר את המודל כמה שיותר עד למועד סיום קבוע. במקרים אחרים, אפשר להמשיך לשפר את המודל ללא הגבלה. לדוגמה, שיפור מתמשך של מודל שנמצא בשימוש בייצור.

באופן עקרוני, אפשר למקסם את הביצועים באמצעות אלגוריתם שמחפש באופן אוטומטי את כל מרחב ההגדרות האפשריות, אבל זו לא אפשרות מעשית. מרחב התצורות האפשריות הוא גדול מאוד, ועדיין אין אלגוריתמים מתוחכמים מספיק כדי לחפש ביעילות במרחב הזה ללא הנחיה אנושית. רוב האלגוריתמים האוטומטיים לחיפוש מסתמכים על מרחב חיפוש שתוכנן באופן ידני ומגדיר את קבוצת ההגדרות לחיפוש, והגדרת מרחבי החיפוש האלה יכולה להיות חשובה מאוד.

הדרך היעילה ביותר למקסם את הביצועים היא להתחיל עם הגדרה פשוטה, להוסיף תכונות בהדרגה ולבצע שיפורים תוך כדי צבירת תובנות לגבי הבעיה.

מומלץ להשתמש באלגוריתמים אוטומטיים לחיפוש בכל סבב של שיפורים, ולעדכן באופן שוטף את מרחבי החיפוש ככל שההבנה שלכם מתרחבת. במהלך השימוש, תגלו באופן טבעי תצורות טובות יותר ויותר, ולכן המודל ה"הכי טוב" שלכם ישתפר כל הזמן.

המונח 'השקה' מתייחס לעדכון של ההגדרה הכי טובה שלנו (שיכול להיות שתתאים או לא תתאים להשקה בפועל של מודל לייצור). לפני כל 'השקה', חשוב לוודא שהשינוי מבוסס על ראיות חזקות – ולא רק על סיכויי אקראי שמבוסס על הגדרה שהצליחה במקרה – כדי שלא תהיה מורכבות מיותרת בצינור ההדרכה.

באופן כללי, אסטרטגיית ההתאמה ההדרגתית שלנו כוללת חזרה על ארבעת השלבים הבאים:

1. **בוחרים יעד לסיבוב הבא של הניסויים.** חשוב לוודא שהיעד מוגדר בהיקף המתאים.
2. **תכנון סבב הניסויים הבא.** לתכנן ולבצע סדרה של ניסויים שיובילו להשגת היעד הזה.
3. **לומדים מהתוצאות של הניסוי.** הערכת הניסוי באמצעות רשימת משימות.

4. **קובעים אם לאמץ את השינוי המוצע.**

בהמשך הקטע הזה מפורטת האסטרטגיה הזו.

בחירת יעד לסיבוב הבא של הניסויים

אם תנסו להוסיף כמה תכונות או לענות על כמה שאלות בבת אחת, יכול להיות שלא תוכלו להפריד בין ההשפעות השונות על התוצאות. דוגמאות ליעדים:

- לנסות שיפור פוטנציאלי של הצינור (לדוגמה, רגולריזטור חדש, בחירה של עיבוד מקדים וכו').

- להבין את ההשפעה של היפר-פרמטר מסוים של המודל (לדוגמה, פונקציית ההפעלה)
- מצמצמים את שגיאת האימות.

עדיפות להתקדמות לטווח ארוך על פני שיפורים בשגיאות אימות לטווח קצר

סיכום: ברוב המקרים, המטרה העיקרית היא לקבל תובנות לגבי בעיית ההתאמה.

מומלץ להקדיש את רוב הזמן להבנת הבעיה, ולהקדיש יחסית מעט זמן לניסיון למקסם את הביצועים בקבוצת האימות. במילים אחרות, כדאי להשקיע את רוב הזמן ב'חיפוש' ורק חלק קטן ב'ניצול'. כדי למקסם את הביצועים הסופיים, חשוב להבין את הבעיה. התמקדות בתובנות במקום ברווחים לטווח קצר עוזרת:

- כדאי להימנע מהשקת שינויים מיותרים שהיו קיימים במקרה בהרצות עם ביצועים טובים, רק בגלל צירוף מקרים היסטורי.
 - לזהות את ההיפרפרמטרים שהשגיאה באימות הכי רגישה להם, את ההיפרפרמטרים שיש ביניהם הכי הרבה אינטראקציות ולכן צריך לכוון אותם מחדש ביחד, ואת ההיפרפרמטרים שהם יחסית לא רגישים לשינויים אחרים ולכן אפשר לתקן אותם בניסויים עתידיים.
 - להציע תכונות חדשות פוטנציאליות לניסיון, כמו שיטות רגולריזציה חדשות אם יש בעיה של התאמת יתר.
 - לזהות תכונות שלא עוזרות ולכן אפשר להסיר אותן, וכך להפחית את המורכבות של ניסויים עתידיים.
 - לזהות מתי סביר להניח שהשיפורים שמתקבלים מכוון היפר-פרמטרים הגיעו לנקודת מיצוי.
 - כדי לשפר את יעילות ההתאמה, כדאי לצמצם את מרחבי החיפוש סביב הערך האופטימלי.
- בסופו של דבר תבינו את הבעיה. אחר כך תוכלו להתמקד רק בשגיאת האימות, גם אם הניסויים לא מספקים מידע רב על מבנה בעיית ההתאמה.

תכנון סבב הניסויים הבא

סיכום: זיהוי ההיפר-פרמטרים המדעיים, המפריעים והקבועים עבור היעד של הניסוי. יוצרים רצף של מחקרים כדי להשוות בין ערכים שונים של היפרפרמטרים מדעיים, תוך אופטימיזציה של היפרפרמטרים מפריעים. בוחרים את מרחב החיפוש של היפרפרמטרים מטרידים כדי לאזן בין עלויות המשאבים לבין הערך המדעי.

זיהוי היפרפרמטרים מדעיים, היפרפרמטרים שקשורים לבעיות והיפרפרמטרים קבועים

לכל יעד נתון, כל ההיפרפרמטרים נכללים באחת מהקטגוריות הבאות:

- **היפרפרמטרים מדעיים** הם פרמטרים שההשפעה שלהם על הביצועים של המודל היא מה שאתם מנסים למדוד.
- **היפרפרמטרים של רעשי רקע** הם היפרפרמטרים שצריך לבצע אופטימיזציה שלהם כדי להשוות בצורה הוגנת בין ערכים שונים של ההיפרפרמטרים המדעיים. היפר-פרמטרים מטרידים דומים לפרמטרים מטרידים בסטטיסטיקה.
- **להיפרפרמטרים קבועים** יש ערכים קבועים בסבב הנוכחי של הניסויים. הערכים של היפרפרמטרים קבועים לא צריכים להשתנות כשמשווים בין ערכים שונים של היפרפרמטרים מדעיים. אם קבועים ערכים מסוימים להיפרפרמטרים עבור קבוצה של ניסויים, צריך להביא בחשבון שהמסקנות שיוסקו מהניסויים האלה לא בהכרח יהיו תקפות להגדרות אחרות של ההיפרפרמטרים הקבועים. במילים אחרות, היפרפרמטרים קבועים יוצרים מגבלות על כל המסקנות שאתם מסיקים מהניסויים.

לדוגמה, נניח שהיעד שלכם הוא:

האם למודל עם יותר שכבות מוסתרות יש שגיאת אימות נמוכה יותר.

במקרה זה:

- קצב הלמידה הוא פרמטר-על בעייתי כי אפשר להשוות בין מודלים עם מספרים שונים של שכבות מוסתרות רק אם קצב הלמידה מותאם בנפרד לכל מספר של שכבות מוסתרות. (שיעור הלמידה האופטימלי בדרך כלל תלוי בארכיטקטורת המודל).
 - פונקציית ההפעלה יכולה להיות היפרפרמטר קבוע אם קבעתם בניסויים קודמים שפונקציית ההפעלה הטובה ביותר לא רגישה לעומק המודל. לחלופין, אפשר להגביל את המסקנות לגבי מספר השכבות הנסתרות כדי לכסות את פונקציית ההפעלה הזו. לחלופין, יכול להיות שזה יהיה היפרפרמטר מעצבן אם אתם מוכנים לכוון אותו בנפרד לכל מספר של שכבות מוסתרות.
 - היפר-פרמטר מסוים יכול להיות היפר-פרמטר מדעי, היפר-פרמטר של רעשי רקע או היפר-פרמטר קבוע. הסיווג של ההיפר-פרמטר משתנה בהתאם ליעד הניסוי. לדוגמה, פונקציית ההפעלה יכולה להיות כל אחת מהאפשרויות הבאות:
 - פרמטר היפר-פרמטר מדעי: האם ReLU או tanh הם בחירה טובה יותר לבעיה שלנו?
 - פרמטר היפר-בעייתי: האם המודל הטוב ביותר עם חמש שכבות טוב יותר מהמודל הטוב ביותר עם שש שכבות כשמאפשרים כמה פונקציות הפעלה שונות?
 - היפרפרמטר קבוע: ברשתות ReLU, האם הוספת נורמליזציה של קבוצות מידע במיקום מסוים עוזרת?
- כשמתכננים סבב חדש של ניסויים:

1. מזהים את ההיפרפרמטרים המדעיים של היעד הניסויי. (בשלב הזה, אפשר להתייחס לכל הפרמטרים האחרים כפרמטרים מעצבנים).

2. המרת חלק מההיפר-פרמטרים המיותרים להיפר-פרמטרים קבועים.

אם היו לכם משאבים בלתי מוגבלים, הייתם משאירים את כל ההיפר-פרמטרים הלא מדעיים כהיפר-פרמטרים מטרידים, כדי שהמסקנות שתסיקו מהניסויים לא יכללו אזהרות לגבי ערכי היפר-פרמטרים קבועים. עם זאת, ככל שמנסים לכוון יותר היפרפרמטרים של רעשי רקע, כך גדל הסיכון שלא תצליחו לכוון אותם בצורה מספיק טובה לכל הגדרה של ההיפרפרמטרים המדעיים, ובסופו של דבר תגיעו למסקנות שגויות מהניסויים. כפי שמתואר ב**קטע בהמשך**, אפשר להקטין את הסיכון הזה על ידי הגדלת התקציב החישובי. עם זאת, התקציב המקסימלי של המשאבים שלכם לרוב נמוך מהתקציב שנדרש כדי לכוון את כל ההיפרפרמטרים הלא-מדעיים.

מומלץ להמיר פרמטר היפר-פרמטר מפריע לפרמטר היפר-פרמטר קבוע אם החסרונות שנובעים מהקבוע שלו פחות משמעותיים מהעלות של הכללתו כפרמטר היפר-פרמטר מפריע. ככל שפרמטר היפר-פרמטר מפריע יותר לאינטראקציה עם ההיפר-פרמטרים המדעיים, כך הנזק שייגרם מתיקון הערך שלו יהיה גדול יותר. לדוגמה, הערך הטוב ביותר של עוצמת דעיכת המשקל תלוי בדרך כלל בגודל המודל, ולכן השוואה בין גדלים שונים של מודלים בהנחה של ערך ספציפי יחיד של דעיכת המשקל לא תהיה מועילה במיוחד.

חלק מהפרמטרים של הכלי לאופטימיזציה

ככלל, חלק מההיפר-פרמטרים של האופטימיזציה (למשל, קצב הלמידה, המומנטום, פרמטרים של תזמון קצב הלמידה, בטא של Adam וכו') הם היפר-פרמטרים מפריעים כי הם נוטים ליצור אינטראקציה עם שינויים אחרים. היפרפרמטרים של אופטימיזציה הם בדרך כלל לא היפרפרמטרים מדעיים, כי מטרה כמו 'מהו קצב הלמידה הטוב ביותר לצינור הנוכחי?' לא מספקת תובנות רבות. בכל מקרה, יכול להיות שההגדרה הכי טובה תשתנה אחרי השינוי הבא בצינור.

יכול להיות שתצטרכו לתקן מדי פעם חלק מהיפרפרמטרים של האופטימיזציה בגלל מגבלות משאבים או בגלל ראיות חזקות במיוחד לכך שהם לא משפיעים על הפרמטרים המדעיים. עם זאת, בדרך כלל צריך להניח שצריך לכוון את ההיפר-פרמטרים של האופטימיזציה בנפרד כדי להשוות בצורה הוגנת בין הגדרות שונות של ההיפר-פרמטרים המדעיים, ולכן לא כדאי לקבע אותם. בנוסף, אין סיבה מראש להעדיף ערך היפרפרמטר

אחד של אופטימיזציה על פני ערך אחר. לדוגמה, ערכי היפרפרמטר של אופטימיזציה בדרך כלל לא משפיעים על העלות החישובית של העברות קדימה או של שיפועים.

בחירת הכלי לאופטימיזציה

בדרך כלל יש שתי אפשרויות לבחירה של כלי אופטימיזציה:

- היפר-פרמטר מדעי
- היפר-פרמטר קבוע

פרמטר אופטימיזציה הוא היפר-פרמטר מדעי אם המטרה של הניסוי היא לבצע השוואות הוגנות בין שני פרמטרים שונים של אופטימיזציה או יותר. לדוגמה:

קובעים איזה כלי אופטימיזציה מפיק את שגיאת האימות הנמוכה ביותר במספר נתון של שלבים.

לחלופין, אפשר להגדיר את האופטימיזציה כהיפרפרמטר קבוע מסיבות שונות, כולל:

- ניסויים קודמים מצביעים על כך שהאופטימיזציה הטובה ביותר לבעיית ההתאמה שלך לא רגישה להיפרפרמטרים מדעיים נוכחיים.
- אתם מעדיפים להשוות בין הערכים של ההיפרפרמטרים המדעיים באמצעות האופטימיזציה הזו, כי קל יותר להסיק מסקנות מהעקומות של האימון שלה.
- אתם מעדיפים להשתמש בכלי האופטימיזציה הזה כי הוא משתמש בפחות זיכרון מהחלופות.

היפר-פרמטרים של רגולריזציה

היפר-פרמטרים שנוצרים על ידי טכניקת רגולריזציה הם בדרך כלל היפר-פרמטרים שוליים. עם זאת, ההחלטה אם לכלול את טכניקת הרגולריזציה היא היפרפרמטר מדעי או קבוע.

לדוגמה, רגולריזציה של נשירה מוסיפה מורכבות לקוד. לכן, כשמחליטים אם לכלול dropout regularization, אפשר להגדיר את ההיפר-פרמטרים 'no dropout' לעומת 'dropout' כהיפר-פרמטרים מדעיים, ואת dropout rate כהיפר-פרמטר מופיע. אם תחליטו להוסיף רגולריזציה של dropout לצנרת על סמך הניסוי הזה, שיעור ה-dropout יהיה היפרפרמטר מופיע בניסויים עתידיים.

היפר-פרמטרים אדריכליים

היפר-פרמטרים ארכיטקטוניים הם לרוב היפר-פרמטרים מדעיים או קבועים, כי שינויים בארכיטקטורה יכולים להשפיע על עלויות ההצגה והאימון, על זמן האחזור ועל דרישות הזיכרון. לדוגמה, מספר השכבות הוא בדרך כלל היפרפרמטר מדעי או קבוע, כי יש לו השפעה משמעותית על מהירות האימון והשימוש בזיכרון.

תלויות בהיפר-פרמטרים מדעיים

במקרים מסוימים, קבוצות ההיפר-פרמטרים הקבועים וההיפר-פרמטרים שמשפיעים על הרעש תלויות בערכים של ההיפר-פרמטרים המדעיים. לדוגמה, נניח שאתם מנסים לקבוע איזה אופטימיזטור במומנטום של נסטרווב וב Adam-מניב את שגיאת האימות הנמוכה ביותר. במקרה זה:

- ההיפרפרמטר המדעי הוא האופטימיזציה, שמקבל ערכים {"Adam", "Nesterov_momentum"},
 - הערך optimizer="Nesterov_momentum" מציג את ההיפרפרמטרים {learning_rate, momentum}, שיכולים להיות היפרפרמטרים קבועים או היפרפרמטרים משתנים.
 - הערך optimizer="Adam" מציג את ההיפר-פרמטרים {learning_rate, beta1, beta2, epsilon}, שיכולים להיות היפר-פרמטרים קבועים או היפר-פרמטרים משתנים.

היפר-פרמטרים שמופיעים רק עבור ערכים מסוימים של ההיפר-פרמטרים המדעיים נקראים **היפר-פרמטרים מותנים**. אל תניחו ששני היפר-פרמטרים מותנים זהים רק בגלל שיש להם את אותו שם. בדוגמה שלמעלה,

ההיפר-פרמטר המותנה שנקרא `learning_rate` הוא היפר-פרמטר שונה עבור `optimizer="Nesterov_momentum"` מאשר עבור `optimizer="Adam"`. המשתנה דומה (אבל לא זהה) בשני האלגוריתמים, אבל טווח הערכים שפועלים היטב בכל אחד מהאופטימיזטורים בדרך כלל שונה בכמה סדרי גודל.

יצירת קבוצה של מחקרים

אחרי שמזהים את ההיפרפרמטרים המדעיים וההיפרפרמטרים שגורמים להפרעות, צריך לתכנן מחקר או רצף של מחקרים כדי להתקדם לעבר היעד של הניסוי. **מחקר** מצוין קבוצה של הגדרות היפר-פרמטרים להרצה לצורך ניתוח בהמשך. כל הגדרה נקראת **ניסיון**. יצירת מחקר בדרך כלל כוללת בחירה של האפשרויות הבאות:

- היפר-פרמטרים שמשתנים בין ניסויים.
 - הערכים שהיפרפרמטרים יכולים לקבל (**מרחב החיפוש**).
 - מספר הניסיונות.
 - אלגוריתם חיפוש אוטומטי לדגימת מספר כה רב של ניסויים ממרחב החיפוש.
- אפשרות אחרת היא ליצור מחקר על ידי הגדרה ידנית של קבוצת ההגדרות של ההיפרפרמטרים.
- מטרת המחקרים היא לבצע בו-זמנית את הפעולות הבאות:
- מריצים את צינור העיבוד עם ערכים שונים של היפרפרמטרים מדעיים.
 - אופטימיזציה של היפרפרמטרים מעצבנים (או אופטימיזציה של היפרפרמטרים) כדי שההשוואות בין ערכים שונים של היפרפרמטרים מדעיים יהיו הוגנות ככל האפשר.
- במקרה הפשוט ביותר, יוצרים מחקר נפרד לכל הגדרה של הפרמטרים המדעיים, כאשר כל מחקר מבצע אופטימיזציה של היפרפרמטרים שאינם רלוונטיים. לדוגמה, אם המטרה היא לבחור את האופטימיזציה הכי טובה מבין Adam, I Nesterov momentum אפשר ליצור שני מחקרים:
- מחקר אחד שבו `optimizer="Nesterov_momentum"` והיפרפרמטרים של רעשי רקע הם `{learning_rate, momentum}`
 - מחקר נוסף שבו `optimizer="Adam"` והיפרפרמטרים של רעשי רקע הם `{learning_rate, beta1, beta2, epsilon}`.

כדי להשוות בין שני כלי האופטימיזציה, בוחרים את הניסוי שמניב את הביצועים הכי טובים מכל מחקר.

אתם יכולים להשתמש בכל אלגוריתם אופטימיזציה ללא גרדיאנט, כולל שיטות כמו אופטימיזציה בייסיאנית או אלגוריתמים אבולוציוניים, כדי לבצע אופטימיזציה של היפרפרמטרים מפריעים. עם זאת, אנחנו מעדיפים להשתמש בחיפוש אקראי למחצה בשלב הניסוי והטעייה של ההתאמה, בגלל היתרונות הרבים שיש לו בהגדרה הזו. אחרי שמסיימים את הניתוח, מומלץ להשתמש בתוכנה מתקדמת לאופטימיזציה בייסיאנית (אם היא זמינה).

נניח שאתם רוצים להשוות בין מספר גדול של ערכים של ההיפר-פרמטרים המדעיים, אבל לא מעשי לבצע כל כך הרבה מחקרים עצמאיים. במקרה כזה, אפשר לבצע את הפעולות הבאות:

- כוללים את הפרמטרים המדעיים באותו מרחב חיפוש כמו ההיפר-פרמטרים של הרעש.
- שימוש באלגוריתם חיפוש כדי לדגום ערכים של ההיפר-פרמטרים המדעיים ושל ההיפר-פרמטרים המפריעים במחקר יחיד.

כשמשתמשים בגישה הזו, היפרפרמטרים מותנים עלולים לגרום לבעיות. בסופו של דבר, קשה לציין מרחב חיפוש אלא אם קבוצת ההיפרפרמטרים המפריעים זהה לכל הערכים של ההיפרפרמטרים המדעיים. במקרה

כזה, אנחנו מעדיפים להשתמש בחיפוש אקראי למחצה במקום בכלי אופטימיזציה מתוחכמים יותר של קופסה שחורה, כי הוא מבטיח דגימה אחידה של ערכים שונים של היפרפרמטרים מדעיים. לא משנה מהו אלגוריתם החיפוש, צריך לוודא שהוא מחפש את הפרמטרים המדעיים באופן אחיד.

איזון בין ניסויים אינפורמטיביים לניסויים במחיר סביר

כשמתכננים מחקר או סדרת מחקרים, צריך להקצות תקציב מוגבל כדי להשיג את שלוש המטרות הבאות:

- השוואה בין מספיק ערכים שונים של היפרפרמטרים מדעיים.
- כוונן של היפרפרמטרים מעצבנים במרחב חיפוש גדול מספיק.
- דגימה של מרחב החיפוש של היפר-פרמטרים מטרידים בצפיפות מספקת.

ככל שתצליחו יותר להשיג את שלושת היעדים האלה, כך תוכלו להפיק יותר תובנות מהניסוי. השוואה של כמה שיותר ערכים של היפרפרמטרים מדעיים מרחיבה את היקף התובנות שאפשר להפיק מהניסוי.

הכללה של כמה שיותר היפר-פרמטרים מפריעים והגדרה של טווח רחב ככל האפשר לכל היפר-פרמטר מפריע מגדילה את הסיכוי למצוא ערך 'טוב' של ההיפר-פרמטרים המפריעים במרחב החיפוש של כל הגדרה של ההיפר-פרמטרים המדעיים. אחרת, יכול להיות שתבצעו השוואות לא הוגנות בין ערכים של היפרפרמטרים מדעיים, כי לא תבצעו חיפוש באזורים אפשריים של מרחב ההיפרפרמטרים המפריעים, שבהם יכולים להיות ערכים טובים יותר עבור חלק מהערכים של הפרמטרים המדעיים.

דוגמים את מרחב החיפוש של היפר-פרמטרים מפריעים בצפיפות גבוהה ככל האפשר. הפעולה הזו מגדילה את הסיכוי שתהליך החיפוש ימצא הגדרות טובות להיפרפרמטרים המיותרים שקיימים במרחב החיפוש. אחרת, יכול להיות שתבצעו השוואות לא הוגנות בין ערכים של הפרמטרים המדעיים, כי חלק מהערכים יקבלו דגימה מוצלחת יותר של היפר-פרמטרים מפריעים.

לצערנו, כדי לשפר את אחד משלושת המאפיינים האלה צריך לבצע אחת מהפעולות הבאות:

- הגדלת מספר הניסויים, ולכן הגדלת עלות המשאבים.
- למצוא דרך לחסוך במשאבים באחד מהמימדים האחרים.

לכל בעיה יש מאפיינים ייחודיים ומגבלות חישוביות משלה, ולכן הקצאת משאבים לשלושת היעדים האלה דורשת ידע מסוים בתחום. אחרי שמריצים מחקר, תמיד כדאי לנסות להבין אם המחקר כוונן את ההיפר-פרמטרים המפריעים בצורה מספיק טובה. כלומר, המחקר חיפש מרחב גדול מספיק באופן מקיף מספיק כדי להשוות בצורה הוגנת את ההיפר-פרמטרים המדעיים (כפי שמתואר בפירוט רב יותר בקטע הבא).

לומדים מהתוצאות של הניסוי

המלצה: בנוסף לניסיון להשיג את המטרה המדעית המקורית של כל קבוצת ניסויים, כדאי לעבור על רשימת שאלות נוספות. אם אתם מגלים בעיות, כדאי לשנות את הניסויים ולהריץ אותם מחדש.

בסופו של דבר, לכל קבוצת ניסויים יש מטרה ספציפית. כדאי לבחון את הנתונים שהניסויים מספקים כדי להבין אם אתם מתקדמים לעבר המטרה. עם זאת, אם שואלים את השאלות הנכונות, אפשר לרוב למצוא בעיות ולתקן אותן לפני שקבוצה מסוימת של ניסויים יכולה להתקדם לעבר המטרה המקורית שלה. אם לא תשאל את השאלות האלה, יכול להיות שתסיק מסקנות שגויות.

הפעלת ניסויים עלולה להיות יקרה, ולכן כדאי גם להפיק תובנות שימושיות אחרות מכל קבוצת ניסויים, גם אם התובנות האלה לא רלוונטיות באופן מיידי למטרה הנוכחית.

לפני שמנתחים קבוצה מסוימת של ניסויים כדי להתקדם לעבר היעד המקורי שלהם, כדאי לשאול את עצמכם את השאלות הנוספות הבאות:

- [האם מרחב החיפוש גדול מספיק?](#) אם הנקודה האופטימלית ממחקר מסוים קרובה לגבול של מרחב החיפוש בממד אחד או יותר, כנראה שהחיפוש לא רחב מספיק. במקרה כזה, כדאי להריץ מחקר נוסף עם מרחב חיפוש מורחב.

- [האם דגמת מספיק נקודות ממרחב החיפוש?](#) אם לא, כדאי להריץ עוד נקודות או להגדיר יעדים פחות שאפתניים.

- איזה חלק מהניסויים בכל מחקר לא אפשריים? כלומר, אילו ניסויים סוטים, מקבלים ערכי הפסד גרועים מאוד או לא מצליחים לפעול בכלל כי הם מפרים אילוץ מרומז כלשהו? אם חלק גדול מאוד מהנקודות במחקר לא אפשריות, צריך לשנות את מרחב החיפוש כדי להימנע מדגימה של נקודות כאלה. לפעמים צריך לשנות את הפרמטרים של מרחב החיפוש. במקרים מסוימים, מספר גדול של נקודות לא אפשריות יכול להצביע על באג בקוד ההדרכה.

- [האם המודל מציג בעיות אופטימיזציה?](#)

- [מה אפשר ללמוד מעקומות האימון של הניסויים הכי טובים?](#) לדוגמה, האם לניסויים הטובים ביותר יש עקומות אימון שתואמות לבעיות של התאמת יתר?

אם יש צורך, על סמך התשובות לשאלות הקודמות, משפרים את המחקר האחרון או את קבוצת המחקרים כדי להרחיב את מרחב החיפוש ו/או להגדיל את מדגם הניסויים, או מבצעים פעולה מתקנת אחרת.



אחרי שעונים על השאלות שלמעלה, אפשר להעריך את הנתונים שהניסויים מספקים ביחס ליעד המקורי. לדוגמה, [הערכה של התועלת של שינוי מסוים](#).

זיהוי גבולות לא טובים של מרחב החיפוש

מרחב חיפוש נחשב לחשוד אם הנקודה הכי טובה שנדגמה ממנו קרובה לגבול שלו. אפשר להרחיב את טווח החיפוש בכיוון הזה כדי למצוא נקודה טובה יותר.

כדי לבדוק את הגבולות של מרחב החיפוש, מומלץ לשרטט ניסויים שהושלמו **בתרשימים בסיסיים של ציר ההיפרפרמטרים**. בגרפים האלה, אנחנו משרטטים את ערך היעד של האימות לעומת אחד מהיפר-פרמטרים (לדוגמה, קצב הלמידה). כל נקודה בתרשים מתאימה לניסיון אחד.

ערך יעד האימות של כל ניסוי צריך להיות בדרך כלל הערך הכי טוב שהושג במהלך האימון.



איור 1: דוגמאות לגבולות לא תקינים של מרחב חיפוש ולגבולות תקינים של מרחב חיפוש.

התרשימים באיור 1 מציגים את שיעור השגיאה (ערך נמוך יותר טוב יותר) לעומת שיעור הלמידה הראשוני. אם הנקודות הכי טובות מתקבצות לקצה של מרחב החיפוש (במאפיין מסוים), יכול להיות שתצטרכו להרחיב את הגבולות של מרחב החיפוש עד שהנקודה הכי טובה שנצפתה לא תהיה יותר קרובה לגבול.

בדרך כלל, מחקר כולל ניסויים 'לא מעשיים' שמתפצלים או מניבים תוצאות גרועות מאוד) מסומנים ב-X-אדום באיור 1. (אם כל הניסויים לא מתאימים לשיעורי למידה שגבוהים מערך סף מסוים, ואם שיעורי הלמידה בניסויים עם הביצועים הכי טובים נמצאים בקצה של האזור הזה, יכול להיות שהמודל סובל מבעיות יציבות שמונעות ממנו לגשת לשיעורי למידה גבוהים יותר).

לא נדגמות מספיק נקודות במרחב החיפוש

באופן כללי, יכול להיות מאוד קשה לדעת אם מרחב החיפוש נדגם בצפיפות מספקת.  עדיף להריץ יותר ניסויים מאשר פחות, אבל יותר ניסויים יוצרים עלות נוספת ברורה.

קשה לדעת מתי דגמתם מספיק נתונים, ולכן אנחנו ממליצים:

- לבדוק מה אתם יכולים להרשות לעצמכם.
- כיול של רמת הביטחון האינטואיטיבית על ידי התבוננות חוזרת בגרפים של ציר ההיפרפרמטרים השונים וניסיון להבין כמה נקודות נמצאות באזור ה"טוב" של מרחב החיפוש.

בדיקת עקומות האימון

סיכום: בדיקת עקומות ההפסד היא דרך קלה לזהות מצבי כשל נפוצים, והיא יכולה לעזור לכם לתעדף פעולות אפשריות.

במקרים רבים, כדי להשיג את המטרה העיקרית של הניסויים, צריך רק להתייחס לשגיאת האימון של כל ניסיון. עם זאת, צריך להיזהר כשמצמצמים כל ניסיון למספר יחיד, כי המיקוד הזה עלול להסתיר פרטים חשובים על מה שקורה מתחת לפני השטח. בכל מחקר, מומלץ מאוד לעיין בעקומות ההפסד של כמה מהניסויים הטובים ביותר לפחות. גם אם זה לא הכרחי כדי להשיג את המטרה העיקרית של הניסוי, בדיקת עקומות ההפסד (כולל הפסד האימון והפסד האימות) היא דרך טובה לזהות מצבי כשל נפוצים, והיא יכולה לעזור לכם לקבוע אילו פעולות כדאי לבצע בהמשך.

כשבדקים את עקומות ההפסד, כדאי להתמקד בשאלות הבאות:

- האם יש ניסויים שבהם יש התאמת יתר בעייתית? בעיה של התאמת יתר מתרחשת כשהשגיאה באימות מתחילה לגדול במהלך האימון. בהגדרות ניסוי שבהן מבצעים אופטימיזציה של היפרפרמטרים לא רלוונטיים על ידי בחירת הניסיון ה"טוב ביותר" לכל הגדרה של ההיפרפרמטרים המדעיים, צריך לבדוק אם יש התאמת יתר בעייתית לפחות בכל אחד מהניסיונות הטובים ביותר שמתאימים להגדרות של ההיפרפרמטרים המדעיים שמשווים ביניהם. אם באחד מהניסויים הטובים ביותר יש התאמת יתר בעייתית, אפשר לבצע את אחת מהפעולות הבאות או את שתיהן:

- מריצים מחדש את הניסוי עם טכניקות רגולריזציה נוספות
- כדאי לכוון מחדש את פרמטרי הרגולריזציה הקיימים לפני השוואת הערכים של ההיפרפרמטרים המדעיים. יכול להיות שההמלצה הזו לא רלוונטית אם הפרמטרים העל-מוגדרים המדעיים כוללים פרמטרים של רגולריזציה, כי אז לא מפתיע שהגדרות של הפרמטרים האלה עם עוצמה נמוכה מובילות להתאמת יתר בעייתית.

לרוב קל לצמצם את התאמת היתר באמצעות טכניקות רגולריזציה נפוצות שמוסיפות מורכבות מינימלית לקוד או חישוב נוסף (לדוגמה, רגולריזציה של נשירה, החלקת תוויות, דעיכת משקל). לכן, בדרך כלל קל להוסיף אחד או יותר מהם לסבב הבא של הניסויים. לדוגמה, אם ההיפרפרמטר המדעי הוא 'מספר השכבות הנסתרות' והניסיון הטוב ביותר שמשתמש במספר הגדול ביותר של שכבות נסתרות מציג התאמת יתר בעייתית, מומלץ לנסות שוב עם רגולריזציה נוספת במקום לבחור מיד את המספר הקטן יותר של שכבות נסתרות.

גם אם באף אחד מהניסויים 'הטובים ביותר' לא זוהה התאמת יתר בעייתית, יכול להיות שיש בעיה אם היא מתרחשת באחד מהניסויים. בחירת הניסוי הטוב ביותר מדכאת הגדרות שמציגות התאמת יתר בעייתית, ומעדיפה הגדרות שלא מציגות התאמת יתר. במילים אחרות, בחירה באפשרות 'הניסיון הטוב ביותר' מעדיפה

הגדרות עם יותר רגולריזציה. עם זאת, כל דבר שפוגע באימון יכול לשמש כרגולריזטור, גם אם זו לא הייתה הכוונה. לדוגמה, בחירה של שיעור למידה קטן יותר יכולה להסדיר את האימון על ידי הגבלת תהליך האופטימיזציה, אבל בדרך כלל לא מומלץ לבחור את שיעור הלמידה בדרך הזו. חשוב לשים לב שאולי המערכת תבחר את תקופת הניסיון 'הטובה ביותר' לכל הגדרה של ההיפרפרמטרים המדעיים באופן שמעדיף ערכים 'גרועים' של חלק מההיפרפרמטרים המדעיים או המטרידים.

- האם יש שונות גבוהה משלב לשלב בשגיאת האימון או האימות בשלב מאוחר באימון? אם כן, יכול להיות שהיא תשפיע על שני הדברים הבאים:

- היכולת להשוות בין ערכים שונים של היפרפרמטרים מדעיים. הסיבה לכך היא שכל תקופת ניסיון מסתיימת באופן אקראי בשלב 'מזל' או 'חוסר מזל'.

- היכולת לשחזר את התוצאה של תקופת הניסיון הטובה ביותר בסביבת הייצור. הסיבה לכך היא שאולי מודל הייצור לא יסתיים באותו שלב 'מזל' כמו במחקר.

הסיבות הסבירות ביותר לשונות בין השלבים הן:

- שונות במקבץ בגלל דגימה אקראית של דוגמאות ממערך האימון לכל מקבץ.

- קבוצות קטנות של נתונים לאימות

- שימוש בקצב למידה גבוה מדי בשלב מאוחר באימון.

פתרונות אפשריים:

- הגדלת גודל האצווה.

- קבלת נתוני אימות נוספים.

- שימוש בדעיכה של קצב הלמידה.


- שימוש בשיטת הממוצע של פוליאק.

- האם עדיין יש שיפורים בניסויים בסוף ההכשרה? אם כן, אתם נמצאים במצב 'מוגבל על ידי חישוב' ויכול להיות שתפיקו תועלת מהגדלת מספר שלבי האימון או משינוי לוח הזמנים של קצב הלמידה.

- האם הביצועים במערכי האימון והאימות הגיעו לנקודת רוויה הרבה לפני שלב האימון הסופי? אם כן, זה מצביע על כך שאתם נמצאים במצב 'לא מוגבל על ידי מחשוב', ואולי תוכלו להקטין את מספר שלבי האימון.

מעבר לרשימה הזו, אפשר לראות הרבה התנהגויות נוספות בגרפים של הפסדי האימון. לדוגמה, אם ההפסד של האימון עולה במהלך האימון, בדרך כלל זה מצביע על באג בצינור העיבוד של האימון.

זיהוי שינוי שימושי באמצעות תרשימי בידוד



איור 2: תרשים בידוד שבדק את הערך הטוב ביותר של דעיכת המשקל עבור ResNet-50 שאומן על ImageNet.

לרוב, המטרה של סדרת ניסויים היא להשוות בין ערכים שונים של היפרפרמטר מדעי. לדוגמה, נניח שאתם רוצים לקבוע את ערך דעיכת המשקל שמניב את שגיאת האימות הטובה ביותר. גרף בידוד הוא מקרה מיוחד של גרף ציר היפרפרמטר בסיסי. כל נקודה בתרשים הבידוד מתאימה לביצועים של הניסוי הכי טוב בחלק מההיפרפרמטרים המפריעים (או בכלם). במילים אחרות, צריך לשרטט את ביצועי המודל אחרי 'אופטימיזציה' של הפרמטרים העודפים.

תרשים בידוד מפשט את ההשוואה בין ערכים שונים של ההיפרפרמטר המדעי. לדוגמה, בעלילה של הבידוד באיור 2 אפשר לראות את הערך של דעיכת המשקל שמניב את ביצועי האימות הטובים ביותר עבור הגדרה מסוימת של ResNet-50 שאומן על ImageNet.

אם המטרה היא להחליט אם לכלול דעיכת משקל בכלל, צריך להשוות את הנקודה הכי טובה מהתרשים הזה לנקודת הבסיס של אי-דעיכת משקל. כדי שההשוואה תהיה הוגנת, צריך לכוון את קצב הלמידה של נקודת הבסיס באותה מידה.

אם יש לכם נתונים שנוצרו על ידי חיפוש (כמעט) אקראי ואתם שוקלים להשתמש בהיפרפרמטר רציף לתרשים בידוד, אתם יכולים ליצור קירוב לתרשים הבידוד על ידי חלוקת ערכי ציר ה-x של תרשים ציר ההיפרפרמטר הבסיסי לקטגוריות, ובחירת הניסיון הטוב ביותר בכל פרוסת נתונים אנכית שמוגדרת על ידי הקטגוריות.

אוטומציה של תרשימים שימושיים באופן כללי

ככל שנדרש יותר מאמץ כדי ליצור תרשימים, כך פחות סביר שתעיינו בהם כמו שצריך. לכן, מומלץ להגדיר את התשתית כך שתפיק כמה שיותר תרשימים באופן אוטומטי. לפחות, מומלץ ליצור באופן אוטומטי תרשימי צירים של היפרפרמטרים בסיסיים לכל ההיפרפרמטרים שמשתנים בניסוי.

בנוסף, מומלץ ליצור באופן אוטומטי עקומות הפסד לכל הניסויים. בנוסף, מומלץ להקל ככל האפשר על מציאת כמה מהניסויים הטובים ביותר בכל מחקר ועל בחינת עקומות ההפסד שלהם.

אפשר להוסיף עוד הרבה תרשימים ורכיבים חזותיים שימושיים. פרפרזה של [ג'פרי הינטון](#):

בכל פעם שאתם מתכננים משהו חדש, אתם לומדים משהו חדש.

החלטה אם לאמץ את השינוי המוצע

סיכום: כשמחליטים אם לבצע שינוי במודל או בהליך ההדרכה, או לאמץ הגדרה חדשה של היפרפרמטרים, חשוב לשים לב למקורות השונות השונים בתוצאות.

כשמנסים לשפר מודל, יכול להיות ששינוי מסוים יניב שגיאת אימות טובה יותר בהשוואה להגדרה הקיימת. עם זאת, יכול להיות שחזרה על הניסוי לא תראה יתרון עקבי. באופן לא רשמי, אפשר לקבץ את המקורות הכי חשובים לתוצאות לא עקביות לקטגוריות הרחבות הבאות:

- **שונות בהליך ההכשרה, שונות בהכשרה מחדש או שונות בניסוי:** השונות בין הרצות של הכשרה משתמשות באותם היפרפרמטרים אבל בערכי התחלה אקראיים שונים. לדוגמה, אתחולים אקראיים שונים, ערבובים של נתוני אימון, מסכות של נשירה, דפוסים של פעולות הגדלת נתונים וסדר של פעולות אריתמטיות מקבילות הם כולם מקורות פוטנציאליים לשונות בניסוי.
- **שונות בחיפוש היפרפרמטרים או שונות במחקר:** השונות בתוצאות שנובעת מההליך שלנו לבחירת ההיפרפרמטרים. לדוגמה, יכול להיות שתריצו את אותו הניסוי עם מרחב חיפוש מסוים, אבל עם שני ערכי seed שונים לחיפוש פסאודו-אקראי, ובסופו של דבר תבחרו ערכים שונים של היפרפרמטרים.
- **שונות של איסוף נתונים ודגימה:** השונות מכל סוג של פיצול אקראי לנתוני אימון, אימות ובדיקה, או שונות שנובעת מתהליך יצירת נתוני האימון באופן כללי יותר.

נכון, אפשר להשוות שיעורי שגיאות אימות שמוערכים על קבוצת אימות סופית באמצעות בדיקות סטטיסטיות קפדניות. עם זאת, לעיתים השונות של הניסוי לבדה יכולה להפיק הבדלים בעלי מובהקות סטטיסטית בין שני מודלים מאומנים שונים שמשתמשים באותן הגדרות של היפרפרמטרים.

הדבר שהכי חשוב לנו הוא השונות במחקר כשמנסים להסיק מסקנות שחורגות מהרמה של נקודה ספציפית במרחב של היפרפרמטרים. השונות במחקר תלויה במספר הניסויים ובמרחב החיפוש. ראינו מקרים שבהם השונות של המחקר גדולה יותר מהשונות של תקופת הניסיון, ומקרים שבהם היא קטנה בהרבה. לכן, לפני שמיישמים שינוי מומלץ, כדאי להריץ את הניסוי הטוב ביותר N פעמים כדי לאפיין את השונות בין הניסויים. בדרך כלל, אפשר להסתפק בסיווג מחדש של השונות בניסוי אחרי שינויים משמעותיים בצינור, אבל במקרים מסוימים יכול להיות שתצטרכו הערכות עדכניות יותר. באפליקציות אחרות, העלות של אפיון השונות בניסוי גבוהה מדי.

אמנם אתם רוצים לאמץ רק שינויים (כולל הגדרות חדשות של היפרפרמטרים) שמניבים שיפורים אמיתיים, אבל גם לא נכון לדרוש ודאות מוחלטת ששינוי מסוים עוזר. לכן, אם נקודה חדשה של היפרפרמטר (או שינוי אחר) מניבה תוצאה טובה יותר מהתוצאה של נקודת הבסיס (בהתחשב בשונות של האימון מחדש של הנקודה החדשה ושל נקודת הבסיס, ככל האפשר), כדאי לאמץ אותה כנקודת הבסיס החדשה להשוואות עתידיות. עם זאת, אנחנו ממליצים לאמץ רק שינויים שמניבים שיפורים שגדולים יותר מכל מורכבות שהם מוסיפים.

אחרי שהחיפוש מסתיים

סיכום: כדאי להשתמש בכלים של אופטימיזציה בייסיאנית אחרי שמסיימים לחפש מרחבי חיפוש טובים ומחליטים אילו היפרפרמטרים כדאי לכוון.

בסופו של דבר, סדר העדיפויות שלכם ישתנה. במקום ללמוד עוד על בעיית ההתאמה, תרצו ליצור את ההגדרה הטובה ביותר להפעלה או לשימוש אחר. בשלב הזה, אמור להיות מרחב חיפוש משופר שמכיל בנוחות את האזור המקומי סביב הניסוי הטוב ביותר שנצפה, ושנדגם בצורה מספקת. תהליך האופטימיזציה אמור לחשוף את ההיפרפרמטרים החיוניים ביותר שצריך לשנות ואת הטווחים הסבירים שלהם. תוכלו להשתמש בטווחים האלה כדי ליצור מרחב חיפוש למחקר סופי של אופטימיזציה אוטומטית, תוך שימוש בתקציב אופטימיזציה גדול ככל האפשר.

[מכיוון שכבר לא חשוב לך למקסם את התובנות לגבי בעיית ההתאמה, הרבה מהיתרונות של חיפוש פסאודו-אקראי כבר לא נלוונטיים. לכן, כדאי להשתמש בכלי אופטימיזציה בייסיאנית כדי למצוא באופן אוטומטי את ההגדרה הטובה ביותר של היפרפרמטרים \[Open-Source Vizier\]\(#\). מיישם מגוון אלגוריתמים מתוחכמים לכוונון מודלים של למידת מכונה, כולל אלגוריתמים של אופטימיזציה בייסיאנית.](#)

נניח שמרחב החיפוש מכיל נפח לא טריוויאלי של **נקודות שונות**, כלומר נקודות שמקבלות הפסד אימון מסוג NaN או אפילו הפסד אימון שגרוע מהממוצע בהרבה סטיות תקן. במקרה כזה, מומלץ להשתמש בכלים לאופטימיזציה של קופסה שחורה שמטפלים בצורה נכונה בניסויים שמתפצלים. (במאמר [אופטימיזציה בייסיאנית עם אילוצים לא ידועים](#) מוסבר על דרך מצוינת לפתור את הבעיה הזו). ל Vizier-בקוד פתוח יש תמיכה בסימון נקודות שונות על ידי סימון ניסויים כלא מעשיים, אבל יכול להיות שהוא לא ישתמש בגישה המועדפת שלנו מתוך [Gelbart et al.](#) בהתאם לאופן ההגדרה שלו.

אחרי שהתהליך מסתיים, כדאי לבדוק את הביצועים במערך הבדיקה. באופן עקרוני, אפשר אפילו לכלול את קבוצת האימות בקבוצת האימון ולאמן מחדש את ההגדרה הטובה ביותר שנמצאה באמצעות אופטימיזציה בייסיאנית. עם זאת, זה מתאים רק אם לא יהיו השקות עתידיות עם עומס העבודה הספציפי הזה) למשל, תחרות חד-פעמית ב-Kaggle).

קובעים את מספר השלבים לכל הרצת אימון

יש שני סוגים של עומסי עבודה של אימון:

- מוגבלת על ידי המחשוב
- לא מוגבל על ידי חישובים

אימון **מוגבל-חישוב** מוגבל על ידי הזמן שאתם יכולים להקדיש לאימון, ולא על ידי כמות נתוני האימון או גורם אחר. במילים אחרות, זמן האימון ה"אופטימלי" הוא תמיד "כמה זמן שמתאים לתקציב שלכם". אם איכשהו אפשר להתאמן למשך זמן ארוך יותר או בצורה יעילה יותר, הפסד האימון אמור לרדת. (אם מכוונים את המודל בצורה נכונה, גם ערך השגיאה של האימות אמור לרדת).

האצת האימון שמוגבל על ידי מחשוב שווה לשיפור האימון. עם זאת, רק בגלל שעומס עבודה מוגבל על ידי חישוב, לא אומר שאימון ארוך יותר או מהיר יותר הוא הדרך היחידה לשפר את התוצאות.

אם האימון לא מוגבל על ידי משאבי מחשוב, אפשר להרשות לעצמכם לאמן את המודל כל עוד תרצו. עם זאת, אימון מודל למשך זמן ארוך יותר לא בהכרח יעזור, ואפילו עלול לגרום ל**התאמת יתר**. אם האימון לא מוגבל על ידי משאבי מחשוב:

- אפשר לאמן את המודל עד להפסד אימון נמוך מאוד, עד לנקודה שבה אימון נוסף עשוי להפחית מעט את הפסד האימון, אבל לא להפחית באופן משמעותי את הפסד האימות.
- קל יותר לבצע אופטימיזציה, במיוחד כשמבצעים אופטימיזציה של לוחות זמנים של ירידה בשיעור הלמידה, כי יש להם אינטראקציה חזקה במיוחד עם תקציב האימון. לעומת זאת, כדי לקבל הפסד אימון נמוך באימון מוגבל-משאבים, יכול להיות שיהיה צורך בשינוי קצב הלמידה בצורה מדויקת.

לא משנה אם עומס עבודה נתון מוגבל על ידי חישוב או לא, שיטות שמגדילות את השונות של הגרדיאנטים (באצווה) בדרך כלל מאטות את התקדמות האימון, ולכן עשויות להגדיל את מספר שלבי האימון שנדרשים כדי להגיע להפסד אימות מסוים. כל אחד מהגורמים הבאים עלול לגרום לשונות גבוהה בשיפוע:

- שימוש בגודל קבוצה קטן יותר.
- הוספת הגדלת נתונים.
- הוספת סוגים מסוימים של רגולריזציה (לדוגמה, רגולריזציה של dropout).

החלטה לגבי משך האימון כשאימון לא מוגבל על ידי משאבי מחשב

המטרה: לאמן את המודל מספיק זמן כדי להגיע לתוצאה הכי טובה שאפשר, בלי לבזבז שלבי אימון.

המטרה העיקרית היא לוודא שהאימון יימשך מספיק זמן כדי שהמודל יגיע לתוצאה הכי טובה שאפשר, בלי לבזבז שלבי אימון מיותרים. אם יש ספק, עדיף להתאמן יותר זמן. מדדי ההערכה (לדוגמה, דיוק, היזכרות, AUC או F_1) לא אמורים אף פעם להידרדר כשהאימון נמשך זמן רב יותר, בהנחה שמשתמשים בצורה נכונה בבחירת נקודות ביקורת רטרופקטיביות ושנקודות הביקורת נבחרות בתדירות גבוהה מספיק.

אל תשנו את המספר `max_train_steps` במחקר. במקום זאת, בוחרים ערך ומשתמשים בו לכל תקופות הניסיון. מתוך הניסויים האלה, יוצרים תרשים של שלב האימון שבו נמצאת הבחירה של נקודת הביקורת הרטרופקטיבית, כדי לשפר את הבחירה של `max_train_steps`.

לדוגמה, אם הצעד הכי טוב תמיד מתרחש במהלך 10% הראשונים של האימון, אז המספר המקסימלי של הצעדים גבוה מדי. לחלופין, אם השלב הכי טוב נמצא באופן עקבי ב-25% האחרונים של האימון, כדאי להאריך את האימון ולשנות את לוח הזמנים של ההפחתה. המספר האידיאלי של שלבי האימון יכול להשתנות כשהארכיטקטורה או הנתונים משתנים (לדוגמה, כשמוסיפים הגדלת נתונים). בקטע הבא מוסבר איך לבחור ערך מועמד ראשוני ל `max_train_steps` על סמך מספר השלבים שנדרשים כדי להתאים באופן מושלם את קבוצת האימון באמצעות קצב למידה קבוע.

הערה: אנחנו לא משתמשים בביטוי "מתאים באופן מושלם לסט האימונים" בצורה מדויקת או מוגדרת היטב מבחינה מתמטית. הביטוי הזה נועד רק לתאר באופן לא רשמי הפסד אימון נמוך מאוד. לדוגמה, כשמבצעים אימון עם פונקציית הפסד הלוגריתמית, ללא מונחי רגולריזציה, יכול להיות שתראו שיפור איטי בהפסד האימון עד שהאימון יגיע למגבלות הדיוק של נקודה צפה. הסיבה לכך היא שהמשקלים של הרשת גדלים ללא גבול, והחיזויים של המודל לגבי מערך האימון הופכים ליותר ויותר בטוחים. במקרה הזה, המודל התאים בצורה מושלמת לנתוני האימון בערך בזמן ששגיאת הסיווג השגוי הגיעה לאפס בנתוני האימון. יכול להיות שתצטרכו להגדיל את ערך ההתחלה של `max_train_steps` אלא כמות הרעש של הגרדיאנט בתהליך האימון גדלה. לדוגמה, כשמוסיפים למודל הגדלת נתונים או אמצעי רגולריזציה כמו dropout.

יכול להיות שאפשר להקטין את `max_train_steps` אם תהליך האימון ישתפר בצורה כלשהי, למשל באמצעות אופטימיזציה מכווננת יותר או באמצעות לוח זמנים מכוון יותר של קצב הלמידה.

אלגוריתם לבחירת מועמד ראשוני לערך `max_train_steps` באמצעות סריקה של שיעור הלמידה

אפשר לבחור מועמד ראשוני ל `max_train_steps` באמצעות אלגוריתם של סריקת שיעורי למידה. האלגוריתם הבא מניח שאפשר לא רק להתאים את מערך האימון בצורה מושלמת, אלא גם לעשות זאת באמצעות תוכנית קבועה של שיעורי למידה.

1. אם אפשר להתאים באופן מושלם את כל מערך האימונים, אז חייבת להיות הגדרה (עם ערך מסוים של `max_train_steps`) שמתאימה באופן מושלם למערך האימונים. מחפשים הגדרה כזו ומשתמשים בערך שלה `max_train_steps` כנקודת התחלה N.

2. מריצים סריקה של קצב למידה קבוע (כלומר, חיפוש רשת של קצב הלמידה) בלי הגדלת נתונים ובלי רגולריזציה, כאשר כל ניסיון אימון נמשך N שלבים. מספר השלבים שנדרשים כדי להגיע לביצועי

אימון מושלמים במהלך חיפוש קצב הלמידה צריך להיות הניחוש הראשוני שלכם לגבי `max_train_steps`.

הערה: מרחבי חיפוש לא טובים עלולים להוביל להונאה עצמית. לדוגמה, אם כל שיעורי הלמידה במחקר קטנים מדי, יכול להיות שתסיקו בטעות שנדרש ערך גדול מאוד של `max_train_steps` לפחות, צריך לוודא ששיעור הלמידה האופטימלי במחקר לא נמצא בגבול של מרחב החיפוש.

החלטה לגבי משך האימון כשמגבלת האימון היא מחשוב

במקרים מסוימים, הפסדי ההדרכה ממשיכים להשתפר ללא הגבלה, ולכן הסבלנות שלכם ומשאבי המחשוב שלכם הופכים לגורמים המגבילים. אבל האם כדאי להתאמן כמה שיותר זמן? לא בהכרח. כמה נקודות שכדאי לזכור:

- יכול להיות שתוכלו לבצע כוונן יעיל יותר על ידי הפעלת מספר גדול יותר של ניסויים קצרים יותר, ולהשאיר את הניסויים הארוכים ביותר (במשך 'זמן הייצור') למודלים שאתם רוצים להשיק.
- ככל שמתקרבים למגבלת הזמן של תקופת הניסיון, ניסויים של התאמת מודלים הופכים רלוונטיים יותר למועמדים פוטנציאליים להשקה, אבל אפשר להשלים פחות ניסויים.
- ברוב המקרים, אפשר לענות על הרבה שאלות אחרי אימון של כ-10% מאורך הסרטון. עם זאת, המסקנות שלכם לגבי מגבלת הזמן הזו לא בהכרח רלוונטיות לניסויים שמתבצעים ב-20% מאורך ההפקה, ובוודאי שלא ב-100%.

גישה הגיונית היא לבצע אופטימיזציה במהלך כמה סבבים עם הגדלה של מגבלות שלבי האימון לכל ניסיון. אפשר להריץ כמה סבבים שרוצים, אבל בדרך כלל הכי פרקטי להריץ סבב אחד עד שלושה. בעצם, כדאי לנסות להבין את הבעיה כמה שיותר טוב באמצעות ניסויים עם זמן תגובה מהיר מאוד, תוך התפשרות על הדברים הבאים:

- היקף הכוונן.
- רלוונטיות לריצות הסופיות הארוכות ביותר.

אחרי שמתקבלות תובנות שימושיות ממגבלת זמן מסוימת לכל ניסיון, מגדילים את זמן האימון וממשיכים לכוון, ובודקים שוב את המסקנות מהריצות הקצרות יותר לפי הצורך. כנקודת התחלה, מומלץ לבצע שני סבבים של התאמה:

- סבב 1: הרצות קצרות יותר כדי למצוא היפרפרמטרים טובים של מודל ואופטימיזציה.
- סיבוב שני: מעט מאוד הרצות ארוכות על נקודות היפרפרמטרים טובות כדי לקבל את המודל הסופי.

השאלה הכי חשובה שעולה מהסיבוב הראשון לסיבוב השני היא:

איך משנים את לוחות הזמנים של ירידה בקצב הלמידה.

אחת הטעויות הנפוצות כשמשנים את לוחות הזמנים של קצב הלמידה בין סבבים היא שימוש בכל שלבי האימון הנוספים עם קצב למידה קטן מדי.

סיבוב ראשון: הרבה אימונים קצרים

לצערנו, אין ערובה לכך שפרמטרים היפר-פרמטרים טובים שנמצאו באימון קצר ולא מלא עדיין יהיו בחירות טובות כשמגדילים באופן משמעותי את משך האימון. עם זאת, לגבי חלק מההיפר-פרמטרים, הבחירות הטובות לרוב קשורות מספיק כדי שהסיבוב הראשון יהיה שימושי. אילו ערכים של היפרפרמטרים שנמצאו בהרצות קצרות מועברים בהצלחה להרצות ארוכות יותר של אימון? אנחנו לא יודעים, אנחנו צריכים לבצע מחקר נוסף. אבל על סמך מה שידוע לנו עד עכשיו, אלה החשדות שלנו בסדר יורד של הסתברות להעברה:

- **סביר מאוד שההעברה תתבצע.** אפשר לפתור חוסר יציבות באימון מוקדם בסיבוב הראשון של ההתאמה באמצעות מספר קטן יותר של שלבי אימון. ההיפר-פרמטרים הבאים הם אלה שהכי סביר שיועברו:

- משך החימום
- אתחול

- **יש סיכוי גבוה להעברה.** שיפור משמעותי בארכיטקטורת המודל בדרך כלל עובר, אבל יש סיכוי גבוה להרבה דוגמאות נגדיות.

- **יכול להיות שההעברה תתבצע.** יכול להיות שההיפרפרמטרים הבאים יועברו:

- אלגוריתם האופטימיזציה וההיפר-פרמטרים יועברו באופן חלקי.
- הגדלת מערך הנתונים.
- רגולריזציה. אם אי אפשר להתאים את מערך האימון בצורה מושלמת, יכול להיות שהמודל נמצא במצב שבו סביר להניח שהרגולריזציה לא תעזור יותר מדי.

- **סביר להניח שההעברה לא תתבצע.** סביר להניח שלוח הזמנים של קצב הלמידה לא יועבר בצורה מושלמת. במאמר [Training Compute-Optimal Large Language Models](#) מוצע להשתמש גם בהעברות של תוכניות דעיכה, אבל אנחנו לא חושבים שזה נכון באופן כללי. לדוגמה, אם מכוונים את הפונקציה sqrt decay למספר קטן של שלבי אימון ואז מרחיבים אותה למספר גדול, רוב האימון מתבצע בשלבים קטנים מדי. סביר להניח שתוכלו להשיג תוצאות טובות עם רוב התזמונים במסגרת תקציב אימון קיצוני, אבל סביר להניח שתראו שיפורים משמעותיים בביצועים אם תבצעו אופטימיזציה. במאמר [Understanding Short-Horizon Bias in Stochastic Meta-Optimization](#) מוסבר על הסכנות בניסיון לבחור שיעורי למידה בצורה קצרת-רואי.

סיבוב שני: פחות ריצות, אבל משך זמן ארוך יותר

מריצים את ההגדרה הכי טובה של היפרפרמטרים מסיבוב 1.

ספקולציה 🤖: השתמש בשלבים הנוספים כדי להאריך את תקופת האימון בקצב למידה גבוה. לדוגמה, אם משתמשים בתזמון ליניארי, צריך להשאיר את אורך הדעיכה קבוע מסיבוב 1 ולהאריך את התקופה של $\sqrt{\text{train_steps}}$ לקבוע בהתחלה. במקרה של דעיכה קוסינוסית, משאירים את הבסיס $\sqrt{\text{train_steps}}$ ומרחיבים את max_train_steps שמתואר במאמר [Training Compute-Optimal Large Language Models](#) אימון מודלים גדולים של שפה עם אופטימיזציה של משאבי מחשב.

יכול להיות שיהיה כדאי לבצע סבבי אימון נוספים לצוותים שמתקיימים בהם כל התנאים הבאים:

- מודלים בוגרים מאוד
- התאמה של צינורות עיבוד נתונים
- הרצות אימון ארוכות ויקרות מאוד

עם זאת, בדרך כלל אין טעם להריץ עוד אימונים.

כבר הסברנו איך עוברים מסבב 1 לסבב 2. אם לא חשוב לכם זמן הניתוח, והדאגה העיקרית שלכם היא שימוש יעיל במשאבי מחשב, מומלץ להגדיל באופן אקספוננציאלי את משך ההרצה של האימון (וכך גם את הזמן הכולל להשלמת המחקר) במהלך סבבים רבים של כוונן:

- בכל סבב, חשוב לוודא באופן שיטתי שהבחירות שלכם ממשיכות לספק תוצאות טובות.
- כדאי להעביר רעיונות חדשים דרך צינור שבו הסיכון שלהם יורד בהדרגה באמצעות ניסויים ארוכים יותר ויותר, משלב i לשלב $i+1$.

הנחיות נוספות לצינור עיבוד הנתונים לאימונים

בקטע הזה מפורט צינור האימון.

אופטימיזציה של צינורות עיבוד נתונים

סיכום: הגורמים לצינורות (pipelines) שמוגבלים על ידי קלט וההתערבויות בהם תלויים מאוד במשימה. משתמשים בכלי ליצירת פרופילים ומחפשים בעיות נפוצות.

כדי לאבחן צינורות עיבוד נתונים שמוגבלים על ידי קלט, צריך להשתמש בכלי פרופיל מתאים, כמו אחד מהכלים הבאים:

- [Perfetto](#) ל-JAX

- [TensorFlow profiler](#) ל-TensorFlow

בסופו של דבר, הסיבות הספציפיות וההתערבויות תלויות מאוד במשימה. שיקולים הנדסיים רחבים יותר (לדוגמה, מזעור טביעת הרגל בדיסק) עלולים לפגוע בביצועים של צינור עיבוד הנתונים של הקלט.

אלה סיבות נפוצות לצינורות שמוגבלים על ידי קלט:

- הנתונים לא ממוקמים יחד עם תהליך האימון, ולכן יש השהיה בקלט/פלט. לדוגמה, קריאת נתוני אימון ברשת עלולה לגרום לזמן אחזור של קלט/פלט.
- עיבוד מקדים יקר של נתונים אונליין. אפשר לבצע עיבוד מקדים במצב אופליין ולשמור את התוצאות.
- מחסומי סנכרון לא מכוונים שמפריעים לאחזור מראש של צינור נתונים. לדוגמה, כשמסנכרנים מדדים בין [המכשיר לבין המארח ב-CommonLoopUtils](#)

אנחנו מציעים את הפתרונות הבאים לצינורות שמוגבלים על ידי קלט:

- [הגדרת צינור הקלט לאחזור מראש של דוגמאות](#) (לדוגמה, [tf.data.Dataset.prefetch](#)),
- מומלץ להסיר תכונות ומטא-נתונים שלא בשימוש מכל אחד מהם בשלב מוקדם ככל האפשר בצינור.
- להגדיל את השכפול של מספר המשימות שיוצרות דוגמאות לצינור הקלט, למשל באמצעות [השירות tf.data](#).

הערכת הביצועים של המודל

סיכום: מריצים הערכה בגדלים גדולים יותר של קבוצות קבצים מאשר באימון. הפעלת הערכות במרווחי שלבים קבועים, ולא במרווחי זמן קבועים.

הגדרות ההערכה

אתם יכולים להשתמש בהגדרות הבאות כדי להעריך את הביצועים של המודלים:

- **הערכה אונליין:** איסוף מדדים כשהמודל מציג תחזיות בסביבת ייצור. הערכה אונליין בדרך כלל מספקת את ההערכה הכי מציאותית של איכות המודל, כי היא תואמת לדרך שבה המודל ישמש.
- **הערכה אופליין:** איסוף מדדים כשהמודל מופעל על מערכי אימון, אימות או בדיקה אופליין שמייצגים את סביבת הייצור. בהתאם לבעיה, הערכה אופליין יכולה להיות מורכבת למדי ולדרוש הרבה משאבי מחשב.
- **הערכות תקופתיות:** איסוף מדדים במהלך אימון המודל שעשויים לשמש כפרוקסי להערכה אופליין, או על קבוצת משנה של הנתונים שמשמשים בהערכה אופליין. הערכות תקופתיות הן הבחירה הכי פרקטית וחسכונית, אבל יכול להיות שהן לא מייצגות באופן מלא את סביבת הייצור. המטרה היא

להשתמש בנתוני פרוקסי נוחים של ההערכה במצב אופליין, בלי לפגוע במהימנות האות שמתקבל במהלך ההערכה.

הגדרת הערכות תקופתיות

מומלץ להריץ הערכות תקופתיות במהלך ההערכה מהסיבות הבאות:

- כדי [לעקוב אחרי התקדמות האימון בזמן אמת](#).
 - כדי להקל על בחירת נקודת ביקורת של מודל רטרוספקטיבי.
 - כדי [לבדוק את עקומות האימון בסוף האימון](#).
- ההגדרה הפשוטה ביותר היא לבצע גם אימון וגם הערכות תקופתיות באותו מופע מחשוב, ולבצע לסירוגין אימון והערכה. במקרה כזה, גודל האצווה שמשמש לביצוע הערכות צריך להיות לפחות כמו גודל האצווה שמשמש לאימון. הסיבה לכך היא שלא צריך לשמור על הפעלת המודלים במהלך ההערכה, ולכן דרישות החישוב לכל דוגמה נמוכות יותר.

מבצעים הערכות תקופתיות במרווחי שלבים קבועים, ולא במרווחי זמן. הערכה על סמך מרווחי זמן יכולה להקשות על פירוש עקומות האימון, במיוחד אם האימון עלול לסבול מהפסקות זמניות של משימות האימון, מבעיות של השהיית רשת וכן הלאה.

מחזוריות במדדי האימות והבדיקה (כשמשמשים בפיצול של מערך אימון, מערך אימות ומערך בדיקה שעברו ערבוב) יכולה להצביע על באגים בהטמעה, כמו:

- נתוני הבדיקה חופפים לנתוני האימון.
 - נתוני האימון לא עוברים ערבוב כמו שצריך.
- אם בודקים את הבעיות האלה במרווחי זמן קבועים, קל יותר לזהות אותן.
- יכול להיות שיהיו קבוצות חלקיות אם קבוצות ההערכה לא מתחלקות בגודל הקבוצה. כדי למנוע הטיה של פונקציית ההפסד, חשוב לוודא שהדוגמאות עם הריפוד מקבלות משקל נכון (כמו בממוצע המשוקלל של הדוגמאות שמשמש לחישוב ההפסד הממוצע של הקבוצה). לעתים קרובות אפשר לתת לדוגמאות המרופדות האלה משקל אפס.

שמירת מספיק מידע לכל הערכה כדי לתמוך בניתוח אופליין. מומלץ לשמור את התחזיות על מבחר של דוגמאות ספציפיות, כי הן יכולות להיות שימושיות מאוד לניפוי באגים. יצירת ארטיפקטים כמו [Saved Models](#) מפשטת את הבדיקה של מודלים אד-הוק אחרי שמשימות ההערכה מסתיימות.

בחירת מדגם להערכה תקופתית

יכול להיות שהתהליך של ההערכה התקופתית לא יפעל מספיק מהר כדי לחשב את המדדים במערך המלא של ההערכה אופליין בזמן סביר. כדי לפתור את הבעיה הזו, צריך לעיתים קרובות לדגום נתונים לצורך הערכה תקופתית. כשיוצרים מערך נתונים מדוגם, חשוב לשים לב לבעיות שקשורות לגודל המדגם ולבעיות מיוחדות במערכי נתונים לא מאוזנים.

גודל המדגם

בודקים שהביצועים שחושבו על קבוצת הנתונים שנדגמה שבה נעשה שימוש במשימה התקופתית תואמים לביצועים בקבוצת ההערכה המלאה של נתוני אופליין. כלומר, מוודאים שאין הטיה בין קבוצת הנתונים שנדגמה לבין קבוצת הנתונים המלאה.

מערך הנתונים שבו אתם משתמשים להערכה תקופתית צריך להיות:

- קטן מספיק כדי ליצור בקלות תחזיות של מודלים על פני כל הנתונים.
- גדול מספיק כדי לבצע את שתי הפעולות הבאות:

- למדוד בצורה מדויקת את השיפורים במודל, כלומר המדידות לא צריכות להיות מושפעות מרעשי תיג.
- להתאים את עצמו למספר הערכות כאלה ברצף במהלך תקופות ניסיון, ועדיין להפיק אומדנים מדויקים. כלומר, גדול מספיק כדי למנוע התאמה דינמית לקבוצת האימות לאורך זמן, באופן שלא מאפשר הכללה לקבוצת בדיקה שהוצאה מראש. עם זאת, השיקול הזה הוא בדרך כלל לא בעיה מעשית.

מערכי נתונים לא מאוזנים

במערכי נתונים לא מאוזנים, הביצועים בסיווגים מיעוטיים נדירים הם לרוב רועשים. במערכי נתונים עם מספר קטן של דוגמאות למיעוט, כדאי לרשום את מספר הדוגמאות שחזיתם בצורה נכונה כדי לקבל תובנות נוספות לגבי שיפורים בדיוק. לדוגמה, שיפור של 0.05 ברגישות נשמע מרשים, אבל האם השיפור נובע רק מדוגמה אחת נוספת שהייתה נכונה?

שמירת נקודות ביקורת ובחירה רטרוספקטיבית של נקודת הביקורת הטובה ביותר

סיכום: מריצים אימון למספר קבוע של שלבים ובוחרים בדיעבד את נקודת הבדיקה הטובה ביותר מתוך הריצה.

רוב ה-frameworks של למידה עמוקה תומכים ב**שמירת נקודות ביקורת (checkpointing)** של מודלים. כלומר, המצב הנוכחי של המודל נשמר בדיסק מעת לעת. הצבת נקודות ביקורת מאפשרת למשימת האימון להיות עמידה בפני הפרעות במכונת המחשוב. נקודת הבדיקה הטובה ביותר היא לא תמיד נקודת הבדיקה האחרונה, במיוחד אם הביצועים של קבוצת האימות לא ממשיכים להשתפר לאורך זמן, אלא משתנים סביב ערך מסוים.

מגדירים את הצינור למעקב אחרי N נקודות הבדיקה הטובות ביותר שנצפו עד עכשיו במהלך האימון. בסיום האימון, בחירת המודל פשוט אומרת בחירה של נקודת הבדיקה הטובה ביותר. הגישה הזו נקראת **בחירה רטרוספקטיבית של נקודת ביקורת אופטימלית**. בדרך כלל אין צורך לתמוך בהפסקת אימון מוקדמת, כי אתם מציינים מראש תקציב לניסוי ושומרים את N נקודות הבדיקה הטובות ביותר שנראו עד עכשיו.

הגדרת מעקב אחר ניסויים

סיכום: כשעוקבים אחרי ניסויים שונים, חשוב לעקוב אחרי מספר נתונים חיוניים, כמו הביצועים הכי טובים של נקודות ביקורת במחקר ותיאור קצר של המחקר.

מומלץ לעקוב אחרי תוצאות הניסוי בגיליון אלקטרוני. הגיליונות האלקטרוניים שלנו לרוב מכילים את העמודות הבאות:

- שם המחקר
 - קישור למיקום שבו מאוחסנת ההגדרה של המחקר.
 - הערות או תיאור קצר של המחקר.
 - מספר תקופות הניסיון שהופעלו
 - ביצועים במערך האימות של נקודת הבדיקה הטובה ביותר במחקר.
 - פקודות שחזרו ספציפיות או הערות לגבי שינויים שלא נשלחו שהיה צורך לבצע כדי להפעיל את ההדרכה.
- מוצאים מערכת נוחה למעקב שמתעדת לפחות את המידע שצוין למעלה. ניסויים שלא מתבצע מעקב אחריהם הם כמו ניסויים שלא קיימים.
- פרטי הטמעה של נירמול באצווה

סיכום: בימינו, אפשר להחליף לעיתים קרובות [נרמול של קבוצות נתונים](#) ב-LayerNorm אבל במקרים שבהם אי אפשר לבצע את ההחלפה הזו, יש פרטים מסובכים כשמשנים את גודל קבוצת הנתונים או את מספר המארחים.

נרמול באצ'ים מנרמל הפעולות באמצעות הממוצע והשונות שלהן באצ' הנוכחי. עם זאת, בהגדרה של כמה מכשירים, הנתונים הסטטיסטיים האלה שונים בכל מכשיר, אלא אם הם מסונכרנים באופן מפורש. דוחות אנקדוטליים) בעיקר ב-ImageNet מצביעים על כך שחישוב נתוני הנורמליזציה האלה באמצעות כ-64 דוגמאות בלבד עובד טוב יותר בפועל. (ראו את התיאור של Ghost Batch Normalization במאמר [Train longer, generalize better: closing the generalization gap in large batch training of neural networks](#)). הפרדה בין גודל האצוה הכולל לבין מספר הדוגמאות שמשמשות לחישוב נתוני הנורמליזציה של האצוה שימושית במיוחד להשוואות בין גדלי אצוה.

הטמעות של נורמליזציה של קבוצות רפאים לא תמיד מטפלות נכון במקרים שבהם גודל הקבוצה לכל מכשיר גדול מגודל הקבוצה הווירטואלית. במקרה כזה, תצטרכו לבצע דגימת משנה של הקבוצה בכל מכשיר כדי לקבל את המספר הנכון של דוגמאות סטטיסטיות של נורמליזציה של קבוצות.

ממוצעים נעים אקספוננציאליים (EMA) שמשמשים לנרמול של קבוצות נתונים במצב בדיקה הם רק שילוב לינארי של נתוני אימון. לכן, צריך לסנכרן את ה-EMA האלה רק לפני ששומרים אותם בנקודות ביקורת. עם זאת, בחלק מהיישומים הנפוצים של נרמול אצוה, המערכת לא מסנכרנת את הממוצעים הנעים האלה ושומרת רק את הממוצע הנע מהמכשיר הראשון.

שיקולים לגבי צינורות עיבוד נתונים עם כמה מארחים

סיכום: באימונים, בהערכות, ב-RNG בנקודות ביקורת ובחלוקת נתונים, אימונים בכמה מארחים יכולים להקל מאוד על הוספת באגים.

לצינורות נתונים עם כמה מארחים, מבצעים את הפעולות הבאות:

- מוודאים שהצינור מבצע רישום ביומן וסימון נקודות עצירה רק במארח אחד.
 - מסנכרנים את הנתונים הסטטיסטיים של הנרמול באצוה בין המארחים לפני ההערכה או יצירת נקודת ביקורת.
 - כדאי לפצל את קובצי הנתונים בין מארחים, כי בדרך כלל זה משפר את הביצועים.
- קריטי:** צריך לוודא שיש לכם ערכי התחלה של RNG שהם זהים בכל המארחים (לאתחול המודל), וערכי התחלה שונים בכל המארחים (לערבול נתונים או לעיבוד מקדים). לכן, חשוב לסמן אותם בצורה מתאימה.

קצב למידה

בנספח הזה מפורטים כמה פרטים נוספים על קצב הלמידה.

תזמון של ירידה בקצב הלמידה

הבעיה של מציאת המשפחה הכי טובה של תוכניות להפחתת קצב הלמידה היא בעיה פתוחה. לא ברור איך לבנות קבוצה של ניסויים קפדניים כדי לענות על השאלה הזו בביטחון. למרות שאנחנו לא יודעים מהו לוח הזמנים הכי טוב למשפחה, אנחנו בטוחים בדברים הבאים:

- חשוב להקפיד על לוח זמנים (לא קבוע).
- חשוב להתאים את לוח הזמנים הזה.

שיעורי למידה שונים מתאימים לשלבים שונים בתהליך האופטימיזציה. אם יש לוח זמנים כלשהו, סביר יותר שהמודל יגיע לשיעור למידה טוב.

הדעיכה הטובה ביותר של שיעור הלמידה שמוגדר כברירת מחדל מומלץ להשתמש באחת מהמשפחות הבאות של שיעורי למידה כברירת מחדל:

- דעיכה לינארית
- דעיכה קוסינוסית

גם הרבה משפחות אחרות של לוחות זמנים כנראה מתאימות.

למה בחלק מהמאמרים יש תוכניות מורכבות של שיעורי למידה?

במאמרים אקדמיים רבים נעשה שימוש בתוכניות מורכבות של ירידה (decay) בקצב הלמידה (LR) בשלבים. קוראים רבים תוהים איך המחברים הגיעו ללוח זמנים כל כך מסובך. הרבה תוכניות מורכבות של דעיכת LR הן תוצאה של כוונן התוכנית כפונקציה של הביצועים של קבוצת האימות בצורה אד-הוקית. כלומר:

1. מתחילים הרצת אימון יחידה עם דעיכה פשוטה של קצב הלמידה (או קצב למידה קבוע).

2. ממשיכים להריץ את האימון עד שהביצועים נראים יציבים. במקרה כזה, צריך להשהות את האימון. לאחר מכן, אפשר להמשיך את האימון עם לוח זמנים של דעיכה תלולה יותר של קצב הלמידה (או קצב למידה קבוע קטן יותר) מהנקודה הזו. חוזרים על התהליך הזה (עד למועד הכנס או מועד ההשקה).

בדרך כלל לא מומלץ להעתיק את לוח הזמנים שמתקבל, כי לוח הזמנים האופטימלי תלוי בהרבה בחירות אחרות של היפרפרמטרים. מומלץ להעתיק את האלגוריתם שיצר את לוח הזמנים, אבל זה כמעט אף פעם לא אפשרי כשלוח הזמנים נוצר על ידי שיקול דעת אנושי שרירותי. אפשר להשתמש בסוג הזה של תזמון שרגיש לשגיאות אימות אם אפשר לבצע אותו באופן אוטומטי לחלוטין, אבל תזמונים שכוללים התערבות אנושית ומתבססים על שגיאות אימות הם בעייתיים וקשה לשחזר אותם, ולכן מומלץ להימנע מהם. לפני פרסום תוצאות שהתקבלו באמצעות תזמון כזה, כדאי לנסות לשחזר אותן באופן מלא.

איך כדאי לכוון את ההיפר-פרמטרים של Adam?

לא כל ההיפרפרמטרים ב Adam חשובים באותה מידה. הכללים הבאים מתאימים ל"תקציבים" שונים של מספר הניסויים במחקר.

- אם יש פחות מ-10 ניסויים במחקר, כדאי לשנות רק את קצב הלמידה (הבסיסי).
- אם יש 10-25 ניסויים במחקר, כדאי לשנות את קצב הלמידה ואת β_1 .
- אם יש לכם יותר מ-25 ניסויים, כדאי לשנות את קצב הלמידה β_1 , ϵ -epsilon.
- אם יש לכם הרבה יותר מ-25 ניסויים, כדאי גם לכוון את β_2 .

קשה לספק כללים כלליים לגבי מרחבי חיפוש וכמה נקודות צריך לדגום ממרחב החיפוש, ולכן הכללים המנחים שמפורטים בקטע הזה הם כללים כלליים בלבד.

חיפוש מעשי אקראי

היחידה הזו מתמקדת בחיפוש כמעט אקראי.

למה כדאי להשתמש בחיפוש כמעט אקראי?

אנחנו מעדיפים חיפוש כמעט אקראי (על סמך רצפים עם אי-התאמה נמוכה) על פני כלים מתוחכמים יותר לאופטימיזציה של תיבת שחורה, כשמשמשים בהם כחלק מתהליך כוונן איטרטיבי שנועד למקסם את התובנות לגבי בעיית הכוונן (מה שאנחנו מכנים 'שלב החקירה'). אופטימיזציה לפי מודלים בייסיאניים וכלים דומים מתאימים יותר לשלב הניצול. חיפוש כמעט אקראי שמבוסס על רצפים עם פערים נמוכים שנדחו באופן

אקראי יכול להיחשב כ'חיפוש רשת עם רעשי גליץ', כי הוא בודק באופן אחיד אבל אקראי מרחב חיפוש נתון ומפיץ את נקודות החיפוש יותר מאשר חיפוש אקראי.

היתרונות של חיפוש כמעט אקראי על פני כלים מתוחכמים יותר לאופטימיזציה של תיבת שחורה (למשל, אופטימיזציה בייסינית, אלגוריתמים אבולוציוניים) כוללים:

- דגימה לא אדפטיבית של מרחב החיפוש מאפשרת לשנות את יעד ההתאמה בניתוח 'אחרי מעשה' בלי להריץ מחדש את הניסויים. לדוגמה, בדרך כלל אנחנו רוצים למצוא את הניסוי הטוב ביותר מבחינת שגיאת האימות שהתקבלה בכל שלב באימון. עם זאת, המאפיין הלא אדפטיבי של חיפוש כמעט אקראי מאפשר למצוא את הניסוי הטוב ביותר על סמך שגיאת האימות הסופית, שגיאת האימון או מדד הערכה חלופי כלשהו, בלי להריץ מחדש את הניסויים.
- חיפוש כמעט אקראי מתנהג באופן עקבי וניתנת לשחזור באופן סטטיסטי. אמורה להיות אפשרות לשחזר מחקר מלפני שישה חודשים גם אם ההטמעה של אלגוריתם החיפוש משתנה, כל עוד הוא שומר על אותם מאפייני אחריות. אם משתמשים בתוכנת אופטימיזציה מתוחכמת מבוססת-בייסיאן, יכול להיות שההטמעה תשתנה באופן משמעותי בין גרסאות, וכך יהיה קשה יותר לשחזר חיפוש ישן. לא תמיד אפשר לחזור לגרסה קודמת של הטמעה (למשל, אם כלי האופטימיזציה פועל כשירות).
- הבדיקה הרגילה של מרחב החיפוש מאפשרת להסיק מסקנות לגבי התוצאות ולגבי מה שהן עשויות להצביע עליו לגבי מרחב החיפוש. לדוגמה, אם הנקודה הטובה ביותר בסריקה של חיפוש כמעט אקראי נמצאת בגבול של מרחב החיפוש, זה סימן טוב (אבל לא ודאי) שצריך לשנות את גבולות מרחב החיפוש. עם זאת, אלגוריתם אופטימיזציה אדפטיבי של תיבת שחורה עשוי להתעלם מחלק ממרחב החיפוש בגלל ניסויים מוקדמים לא מוצלחים, גם אם הוא מכיל נקודות טובות באותה מידה. הסיבה לכך היא שזהו בדיוק סוג אי-העקביות שצריך להשתמש בו באלגוריתם אופטימיזציה טוב כדי לזרז את החיפוש.
- כשמשתמשים בחיפוש כמעט אקראי (או באלגוריתמים אחרים של חיפוש לא אדפטיבי), אין הבדל סטטיסטי בין הפעלת מספרים שונים של ניסויים במקביל לבין הפעלת מספרים שונים של ניסויים ברצף, בניגוד לאלגוריתמים אדפטיביים.
- אלגוריתמים מתוחכמים יותר של חיפוש לא תמיד מטפלים נכון בנקודות לא ריאליות, במיוחד אם הם לא תוכננו תוך התחשבות בהתאמה של פרמטרים היפר-מרחביים של רשתות נוירונליות.
- חיפוש כמעט אקראי הוא פשוט ופועל במיוחד טוב כשמפעילים בו-זמנית הרבה ניסויים לכוונון. לפי נתונים אנקדוטיים,¹ קשה מאוד לאלגוריתם אדפטיבי לנצח חיפוש כמעט אקראי עם תקציב כפול, במיוחד כשצריך להריץ הרבה ניסויים במקביל (ולכן יש מעט מאוד הזדמנויות להשתמש בתוצאות של ניסויים קודמים כשמפעילים ניסויים חדשים). ללא מומחיות באופטימיזציה לפי מודלים בייסיאניים ובשיטות מתקדמות אחרות של אופטימיזציה בקופסה שחורה, יכול להיות שלא תשיגו את היתרונות שהן יכולות לספק, באופן עקרוני. קשה להשוות בין אלגוריתמים מתקדמים של אופטימיזציה בקופסה שחורה בתנאים ריאליסטיים של כונון למידה עמוקה. זהו תחום פעיל מאוד של מחקר, ולכל אלגוריתם מתוחכם יש מלכודות משלו למשתמשים חסרי ניסיון. מומחים בשיטות האלה יכולים להשיג תוצאות טובות, אבל בתנאים של מקביליות גבוהה, מרחב החיפוש והתקציב נוטים להיות חשובים הרבה יותר.

עם זאת, אם משאבי המחשוב שלכם מאפשרים להריץ רק מספר קטן של ניסויים במקביל, ואתם יכולים להרשות לעצמכם להריץ הרבה ניסויים ברצף, אופטימיזציה בייסינית הופכת לאטרקטיבית הרבה יותר, למרות שקשה יותר לפרש את תוצאות ההתאמה.

איפה אפשר למצוא הטמעה של חיפוש כמעט אקראי?

ב [Vizir-בקוד פתוח](#) יש [הטמעה של חיפוש כמעט אקראי](#). מגדירים


את "algorithm="QUASI_RANDOM_SEARCH" [בדוגמה הזו לשימוש ב-Vizier](#)-אפשר למצוא הטמעה חלופית [בדוגמה הזו של סריקות של פרמטרים היפר-מרחביים](#). שתי הטמעות האלה יוצרות רצף Halton

למרחב חיפוש נתון (המטרה היא להטמיע רצף Halton שעבר דחיפה וערבוב, כפי שמומלץ במאמר [פרמטרים היפר-קריטיים: ללא אקראיות, ללא קריאה](#)).

אם לא זמין אלגוריתם חיפוש כמעט אקראי שמבוסס על רצף עם אי-התאמה נמוכה, אפשר להחליף אותו בחיפוש אחיד פסאודו-אקראי, אבל סביר להניח שהיעילות שלו תהיה מעט נמוכה יותר. כשמשתמשים ב-1-2 מאפיינים, אפשר גם לבצע חיפוש ברשימה, אבל לא במאפיינים רבים יותר. (ראו [Bergstra & Bengio, 2012](#)).

כמה ניסיונות נדרשים כדי לקבל תוצאות טובות בחיפוש כמעט אקראי?

אין דרך לקבוע כמה ניסיונות נדרשים כדי לקבל תוצאות בחיפוש כמעט אקראי באופן כללי, אבל אפשר להיעזר בדוגמאות ספציפיות. כפי שמוצג באיור 3, למספר הניסויים במחקר יכולה להיות השפעה משמעותית על התוצאות:



איור 3 ResNet-50: שהותאמה ב ImageNet עם 100 ניסיונות. באמצעות טעינה ראשונית (bootstrapping), בוצעה סימולציה של סכומים שונים של תקציב לכוונון. מוצגים תרשימים של תיבות עם הביצועים הטובים ביותר לכל תקציב ניסיוני.

שימו לב לפרטים הבאים לגבי איור 3:


- טווחי הרבעונים כשנלקחו 6 ניסויים לדגימה גדולים בהרבה מאשר כשנלקחו 20 ניסויים לדגימה.
- גם עם 20 ניסיונות, סביר להניח שההבדל בין ניסויים עם מזל טוב במיוחד לבין ניסויים עם מזל רע במיוחד גדול מהשונות הרגילה בין אימון מחדש של המודל הזה עם זרעים אקראיים שונים, עם פרמטרים היפר-מוגדרים קבועים. עבור עומס העבודה הזה, השונות יכולה להיות בערך +/- 0.1% בשיעור שגיאות האימות של כ-23%.

1. בן רייט (Ben Recht) וקווין ג'יימסון (Kevin Jamieson) [צינו](#) עד כמה חיפוש אקראי עם תקציב כפול חזק כבסיס ([במאמר על Hyperband](#) מופיעים טיעונים דומים), אבל אפשר בהחלט למצוא מרחבי חיפוש ובעיות שבהם שיטות אופטימיזציה בייסיניות מתקדמות משיקות חיפוש אקראי עם תקציב כפול. עם זאת, לדעתנו קשה יותר להשיג תוצאות טובות יותר מחיפוש אקראי עם תקציב כפול במצב של מקביליות גבוהה, כי לאופטימיזציה הבאינית אין הזדמנות לצפות בתוצאות של ניסויים קודמים.

שאלות נפוצות

איך אפשר לנפות באגים בבעיות באופטימיזציה ולצמצם את ההשפעה שלהן?

סיכום: אם המודל נתקל בקשיים באופטימיזציה, חשוב לפתור אותם לפני שמנסים דברים אחרים. אנחנו עדיין עורכים מחקרים בנושא אבחון של כשלים באימון ותיקון שלהם.



איור 4. שינוי הצעדים בבולק שיורי יחיד (2x1 -> 2x2 WideResnet-גורם לחוסר יציבות באימון).

שימו לב לנקודות הבאות לגבי איור 4:

- שינוי הצעדים לא פוגע בביצועים בשיעורי למידה נמוכים.

- שיעורי למידה גבוהים כבר לא מאפשרים אימון טוב בגלל חוסר יציבות.
- החלת 1,000 שלבים של חימום קצב הלמידה פותרת את המקרה הספציפי הזה של חוסר יציבות, ומאפשרת אימון יציב בקצב למידה מקסימלי של 0.1.


זיהוי עומסי עבודה לא יציבים

כל עומס עבודה הופך ללא יציב אם קצב הלמידה גדול מדי. חוסר יציבות הוא בעיה רק אם הוא מחייב שימוש בקצב למידה קטן מדי. יש לפחות שני סוגים של חוסר יציבות באימון שכדאי להבחין ביניהם:

- חוסר יציבות בתחילת האימון או בשלב מוקדם שלו.
- חוסר יציבות פתאומי באמצע האימון.

כדי לזהות בעיות ביציבות של עומס העבודה, אפשר לפעול באופן שיטתי:

- מבצעים סריקה של קצב הלמידה ומוצאים את קצב הלמידה הטוב ביותר. lr^*
 - משרטטים עקומות של הפסדי אימון לשיעורי למידה שגבוהים רק מעט מ. lr^*
 - אם שיעורי הלמידה $lr^* >$ מראים חוסר יציבות בהפסד (ההפסד עולה ולא יורד במהלך תקופות האימון), בדרך כלל תיקון חוסר היציבות משפר את האימון.
- מתעדים את נורמת L2 של שיפוע ההפסד המלא במהלך האימון, כי ערכים חריגים יכולים לגרום לחוסר יציבות מזויף באמצע האימון. המידע הזה יכול לעזור להבין עד כמה כדאי להגביל את הגרדיאנטים או את עדכוני המשקלים.
- הערה: בדגמים מסוימים נצפית חוסר יציבות בשלב מוקדם מאוד, ואחריו מתרחש שיפור שמוביל לאימון איטי אבל יציב. בדרך כלל, לוחות זמנים נפוצים להערכה לא מצליחים לזהות את הבעיות האלה כי הם לא מתבצעים בתדירות גבוהה מספיק.
- כדי לבדוק את זה, אפשר להריץ אימון מקוצר של כ-500 שלבים בלבד באמצעות $lr = 2 * \text{current best}$, אבל להעריך כל שלב.




איור 5. הערך של הערכות תכופות יותר בתחילת ההדרכה. האפשרות הזו שימושית אם אתם חושדים שהמודל סובל מחוסר יציבות בשלב מוקדם של האימון.

תיקונים אפשריים לדפוסי חוסר יציבות נפוצים

הנה כמה פתרונות אפשריים לדפוסי חוסר יציבות נפוצים:


- החלה של תקופת הכנה לשיעור הלמידה. האפשרות הזו מתאימה במיוחד לחוסר יציבות בשלב מוקדם של האימון.
- החלת חיתוך של צבע מדורג. השיטה הזו טובה לחוסר יציבות בשלבים מוקדמים ובשלבי אמצע של האימון, והיא עשויה לתקן אתחולים שגויים שחימום לא יכול לתקן.
- כדאי לנסות כלי אופטימיזציה חדש. לפעמים Adam יכול להתמודד עם חוסר יציבות ש-Momentum לא יכול. זהו תחום מחקר פעיל.
- חשוב לוודא שאתם משתמשים בשיטות מומלצות ובאתחולים הטובים ביותר לארכיטקטורת המודל (דוגמאות בהמשך). מוסיפים חיבורים שיריים ונורמליזציה אם המודל לא מכיל אותם.
- מבצעים נורמליזציה כפעולה האחרונה לפני השארית. לדוגמה: $x + \text{Norm}(f(x))$: שימו לב ששימוש ב- $\text{Norm}(x + f(x))$ עלול לגרום לבעיות.
- כדאי לנסות לאתחל ענפים שיריים ל-0. (ראו [ReZero is All You Need: Fast Convergence at Large Depth.](#))
- להקטין את קצב הלמידה. זו האפשרות האחרונה.

חימום קצב הלמידה




איור 6. דוגמה לחוסר יציבות במהלך תקופת החימום (שימו לב לסולם הלוגריתמי של הציר האופקי). במקרה הזה, נדרשו 40,000 צעדים של חימום כדי שהאימון יצליח.

מתי כדאי להשתמש בחימום של קצב הלמידה



איור 7א. דוגמה לתרשים של ציר היפרפרמטרים של מודל שמציג חוסר יציבות באימון. שיעור הלמידה הטוב ביותר הוא בגבול האפשרי. ניסוי 'לא אפשרי' הוא ניסוי שמפיק ערכי NaN או ערכים גבוהים באופן לא אופייני של הפסד.




איור 7ב. הפסד האימון של מודל שאומן עם

איור 7א מציג תרשים של ציר היפרפרמטרים שמצביע על מודל שחוזה חוסר יציבות באופטימיזציה, כי קצב הלמידה הטוב ביותר נמצא ממש בקצה של חוסר היציבות.

באיור 7ב מוצג איך אפשר לבדוק את זה באמצעות בחינת הפסד האימון של מודל שאומן עם קצב למידה שגדול פי 5 או פי 10 מהשיא הזה. אם בתרשים הזה רואים עלייה פתאומית בערך ה loss-אחרי ירידה יציבה (לדוגמה, בשלב 10k~ בתרשים שלמעלה, (סביר להניח שהמודל סובל מחוסר יציבות באופטימיזציה).

איך משתמשים בחימום של קצב הלמידה



איור 8. השפעה חיובית של חימום קצב הלמידה על טיפול בחוסר יציבות באימון.

נסמן ב `unstable_base_learning_rate` את קצב הלמידה שבו המודל הופך ללא יציב, באמצעות התהליך הקודם.

חימום כולל הוספה של תזמון קצב למידה שמגדיל את קצב הלמידה מ-0 לערך יציב `base_learning_rate` שהוא לפחות בסדר גודל אחד גדול יותר מ `unstable_base_learning_rate`. ברירת המחדל תהיה לנסות `base_learning_rate` שהוא פי 10 מ `unstable_base_learning_rate` אבל אפשר לחזור על התהליך הזה לגבי משהו כמו 100. `unstable_base_learning_rate` הזמנים הספציפי הוא:

- תקופת הרצה מ-0 עד `base_learning_rate` על פני `warmup_steps`
- אימון בקצב קבוע למשך `post_warmup_steps`

המטרה היא למצוא את מספר ה `warmup_steps` הקצר ביותר שיאפשר לכם לגשת לשיעורי למידה גבוהים בהרבה מ `unstable_base_learning_rate`, לכל `base_learning_rate` צריך לשנות את `warmup_steps` ואת `post_warmup_steps` בדרכך כלל אפשר להגדיר את `post_warmup_steps` כ- $2 * \text{warmup_steps}$.


אפשר לשנות את ההגדרות של תקופת ההרצה בנפרד מלוח זמנים קיים של דעיכה `warmup_steps`. צריך להשתמש בכמה סדרי גודל שונים. לדוגמה, מחקר יכול לנסות `[10, 1000, 10,000, 100,000]` הנקודה הכי גדולה האפשרית לא יכולה להיות יותר מ-10% מ `max_train_steps`.

אחרי שמגדירים `warmup_steps` שלא גורם לאימון להתפוצץ ב `base_learning_rate` צריך להחיל אותו על מודל הבסיס. בעצם, מוסיפים את לוח הזמנים הזה לפני לוח הזמנים הקיים, ומשתמשים בבחירת נקודות הבדיקה האופטימלית שצוינה למעלה כדי להשוות את הניסוי הזה לערך הבסיס. לדוגמה, אם במקור היו `max_train_steps` 10,000 ועשינו `warmup_steps` ל-1,000 שלבים, הליך האימון החדש צריך לרוץ ל-11,000 שלבים בסך הכול.

אם נדרשים `warmup_steps` ארוכים לאימון יציב (יותר מ-5% מ `max_train_steps`), יכול להיות שתצטרכו להגדיל את `max_train_steps` כדי להתחשב בכך.

אין באמת ערך 'טיפוסי' בכל טווח העומסים. יש מודלים שנדרשים להם רק 100 שלבים, ויש מודלים (במיוחד טרנספורמטורים) שנדרשים להם 40,000 שלבים ויותר.

חיתוך הדרגתי



איור 9 Gradient clipping correcting early training instability..

חיתוך שיפועים שימושי במיוחד כשמתרחשות בעיות גדולות או חריגות בשיפועים. התכונה 'חיתוך הדרגתי' יכולה לפתור את הבעיות הבאות:

- חוסר יציבות מוקדם באימון (נורמת גרדיאנט גדולה בשלב מוקדם)
 - חוסר יציבות במהלך האימון (עליות פתאומיות בשיפוע במהלך האימון).
- לפעמים תקופות חימום ארוכות יותר יכולות לתקן חוסר יציבות שלא ניתן לתקן באמצעות חיתוך. לפרטים נוספים, אפשר לעיין במאמר בנושא [חימום קצב הלמידה](#).

מה לגבי חיתוך במהלך החימום?

הסף האידיאלי לקליפים הוא קצת מעל הנורמה של השיפוע ה'טיפוסי'.

דוגמה לאופן שבו אפשר לבצע חיתוך של מעברי צבע:

- אם הנורמה של הגרדיאנט גדולה מסף חיתוך הגרדיאנט, אז מתבצעת הפעולה כאשר הוא הגרדיאנט החדש.

תיעוד הנורמה של הגרדיאנט שלא נחתך במהלך האימון. כברירת מחדל, המערכת יוצרת:

- תרשים של נורמת הגרדיאנט לעומת השלב
- היסטוגרמה של נורמות הגרדיאנטים שנצברות על פני כל השלבים

בוחרים סף לחיתוך הדרגתי על סמך האחוזון ה-90 של נורמות הדרגתיות. הסף תלוי בעומס העבודה, אבל 90% הם נקודת התחלה טובה. אם 90% לא עובד, אפשר לשנות את ערך הסף הזה.

מה לגבי שיטה אדפטיבית כלשהי?

אם מנסים לגזור את הגרדיאנט ובעיות חוסר היציבות נמשכות, אפשר לנסות לגזור אותו בצורה חזקה יותר, כלומר להקטין את ערך הסף.

חיתוך גרדיאנט אגרסיבי במיוחד (כלומר, חיתוך של יותר מ-50% מהעדכונים) הוא למעשה דרך מוזרה להפחית את קצב הלמידה. אם אתם משתמשים בחיתוך אגרסיבי במיוחד, כדאי פשוט להקטין את קצב הלמידה.

למה קצב הלמידה ופרמטרים אחרים של אופטימיזציה נקראים היפר-פרמטרים? הם לא פרמטרים של אף התפלגות קודמת.

למונח 'היפר-פרמטר' יש [משמעות מדויקת](#) בלמידת מכונה בייסיאנית, ולכן השימוש במונח הזה לתיאור קצב הלמידה ורוב הפרמטרים האחרים של למידה עמוקה שניתנים לכוונון הוא שימוש לא מדויק במיוחד. אנחנו מעדיפים להשתמש במונח 'מטא-פרמטר' לתיאור של שיעורי למידה, פרמטרים ארכיטקטוניים וכל שאר הדברים שניתנים להתאמה אישית בלמידה עמוקה. הסיבה לכך היא שהמטא-פרמטר מונע בלבול פוטנציאלי שנובע משימוש לא נכון במילה 'היפר-פרמטר'. הבלבול הזה סביר במיוחד כשמדובר באופטימיזציה בייסיאנית, שבה למודלים של משטחי תגובה הסתברותיים יש היפרפרמטרים משלהם.

למרות שהמונח 'היפר-פרמטר' עלול להיות מבלבל, הוא נפוץ מאוד בקהילת הלמידה העמוקה. לכן, במסמך הזה, שמיועד לקהל רחב שכולל הרבה אנשים שלא סביר שיכירו את הפרט הטכני הזה, בחרנו לתרום למקור אחד של בלבול בתחום בתקווה להימנע ממקור אחר. עם זאת, יכול להיות שנשתמש במונח אחר כשנפרסם מאמר מחקר, ונמליץ לאחרים להשתמש במונח 'מטא-פרמטר' ברוב ההקשרים.

למה לא כדאי לשנות את גודל האצווה כדי לשפר ישירות את הביצועים של קבוצת האימון?

שינוי גודל האצווה בלי לשנות פרטים אחרים [בצינור ההכשרה](#) משפיע לעיתים קרובות על הביצועים של קבוצת האימון. עם זאת, ההבדל בביצועים של קבוצת האימון בין שני גדלים של אצווה בדרך כלל נעלם אם צינור ההדרכה עובר אופטימיזציה באופן עצמאי לכל גודל אצווה.

ההיפרפרמטרים שמקיימים את האינטראקציה הכי חזקה עם גודל האצווה, ולכן הכי חשוב לכוון אותם בנפרד לכל גודל אצווה, הם ההיפרפרמטרים של האופטימיזציה (לדוגמה, קצב הלמידה, המומנטום) וההיפרפרמטרים של הרגולריזציה. גודלי אצווה קטנים יותר מוסיפים יותר רעשי רקע לאלגוריתם האימון בגלל השונות במדגם. הרעש הזה יכול להשפיע על הרגולריזציה. לכן, גדלים גדולים יותר של אצווה יכולים להיות מועדים יותר להתאמת יתר, ועשויים לדרוש רגולריזציה חזקה יותר ו/או טכניקות רגולריזציה נוספות. בנוסף, יכול להיות שתצטרכו [לשנות את מספר שלבי האימון](#) כשמשנים את גודל האצווה.

אחרי שמביאים בחשבון את כל ההשפעות האלה, אין ראיות משכנעות לכך שגודל האצווה משפיע על ביצועי האימון המקסימליים שאפשר להשיג. פרטים נוספים זמינים במאמר [Shallue et al. 2018](#).

מהם כללי העדכון של כל אלגוריתמי האופטימיזציה הפופולריים?

בקטע הזה מפורטים כללי עדכון לכמה אלגוריתמים פופולריים של אופטימיזציה.

ירידה סטוכסטית של גרדיאנט (SGD)

כאשר הוא קצב הלמידה בשלב .

מומנטום

כאשר הוא קצב הלמידה בשלב , ו- הוא מקדם המומנטום.

Nesterov

כאשר הוא קצב הלמידה בשלב ו, הוא מקדם המומנטום.

RMSProp

ADAM

NADAM